VIETNAM NATIONAL UNIVERSITY, HO CHI MINH CITY
UNIVERSITY OF TECHNOLOGY
FACULTY OF COMPUTER SCIENCE AND ENGINEERING

Semester: 251

Phân tích cảm xúc trên Twitter

Khai phá dữ liệu

Teacher: Đỗ Thanh Thái
Students: Trần Quốc Khánh - 2211536
Đinh Nguyễn Việt Khiêm - 2211565
Nguyễn Huy Hoàng - 2211091

HO CHI MINH, November 2025

Contents

1 Danh sách thành viên **4**

2 Giới thiệu **5**

3 Tiền xử lí dữ liệu **6**

3.1 Tổng quan về dữ liệu 6

3.2 Đặc điểm của dữ liệu văn bản Twitter 8

3.3 Các bước tiền xử lý dữ liệu 9

3.3.1 Loại bỏ dữ liệu không cần thiết 9

3.3.2 Làm sạch văn bản (Text Cleaning) 10

3.3.3 Loại bỏ từ dừng (Stopwords Removal) 11

3.3.4 Chuẩn hóa từ vựng (Stemming / Lemmatization) 11

3.3.5 Kết quả sau khi tiền xử lý 11

3.4 Đánh giá chất lượng dữ liệu sau tiền xử lý 12

3.4.1 Độ sạch và tính thống nhất của dữ liệu 12

3.4.2 Tính cân bằng giữa các nhãn cảm xúc 13

3.4.3 Phân tích tần suất từ khóa 13

3.4.4 Đánh giá tổng thể 14

4 Phương pháp thực hiện **15**

4.1 K-Nearest Neighbor (KNN) 15

4.1.1 Cơ sở lý thuyết về K-Nearest Neighbors (KNN) 15

4.1.2 Nguyên lý hoạt động 15

4.1.3 Các yếu tố quan trọng 15

4.1.4 Ưu điểm và nhược điểm 16

4.1.4.a Ưu điểm 16

4.1.4.b Nhược điểm 16

4.1.5 Ứng dụng 17

4.1.6 Lưu ý thực tiễn 17

4.1.7 Hiện thực 17

4.1.7.a Chuẩn bị dữ liệu 17

4.1.7.b Hiện thực mô hình 18

4.1.7.c Chạy mô hình 19
4.1.7.d Kết quả thu được 19
4.2 NAIVE BAYES 20
4.2.1 Cơ sở lý thuyết về Naive Bayes 20
4.2.2 Cách hoạt động 21
4.2.3 Các loại Naive Bayes phổ biến 21
4.2.4 Ưu điểm và nhược điểm 22
4.2.4.a Ưu điểm 22
4.2.4.b Nhược điểm 22
4.2.5 Ứng dụng 22
4.2.6 Lưu ý thực tiễn 23
4.2.7 Hiện thực 23
4.2.7.a Chuẩn bị dữ liệu 23
4.2.7.b Hiện thực mô hình 24
4.2.7.c Chạy mô hình 24
4.2.7.d Kết quả thu được 25
4.3 LOGISTIC REGRESSION 26
4.3.1 Cơ sở lý thuyết về Logistic Regression 26
4.3.2 Hàm mất mát (Binary Cross-Entropy) 26
4.3.3 Ưu điểm và Nhược điểm 27
4.3.4 Ứng dụng 27
4.3.5 Hiện thực 28
4.3.5.a Chuẩn bị dữ liệu 28
4.3.5.b Huấn luyện mô hình 28
4.3.5.c Đánh giá mô hình 29
4.3.5.d Kết quả thu được 29

5 Đánh giá **31**
5.1 Các chỉ số đánh giá 31
5.1.1 Ma trận Nhầm lẫn (Confusion Matrix) 31
5.1.2 Accuracy (Độ chính xác tổng thể) 31
5.1.3 Precision (Độ chính xác của dự đoán) 32
5.1.4 Recall (Độ bao phủ hay còn là TPR) 33

5.1.5 F1-Score (Chỉ số cân bằng Precision và Recall) 33
5.2 Đánh giá mô hình K-Nearest Neighbors (KNN) 34
5.2.1 Trực quan hóa kết quả 34
5.2.2 Các chỉ số đánh giá tổng hợp 35
5.2.3 Phân tích đường cong ROC (Receiver Operating Characteristic) 36
5.2.4 Kết luận từ ROC Curve 37
5.2.5 Nhận xét và kết luận 38
5.3 Đánh giá mô hình Multinomial Naive Bayes (MNB) 38
5.3.1 Trực quan hóa kết quả 38
5.3.2 Phân tích đường cong ROC (Receiver Operating Characteristic) 39
5.3.3 Các chỉ số đánh giá tổng hợp 41
5.3.4 Nhận xét và kết luận 41
5.4 Đánh giá Mô hình Hồi quy Logistic (Logistic Regression) 42
5.4.1 Trực quan hóa kết quả 42
5.4.2 Phân tích Đường cong ROC (Receiver Operating Characteristic) 43
5.4.3 Các chỉ số đánh giá tổng hợp 44
5.4.4 Nhận xét và kết luận 44

6 So sánh hiệu suất giữa ba mô hình 45
6.1 Biểu đồ so sánh hiệu suất 45
6.2 Bảng so sánh chi tiết 46
6.3 Phân tích và nhận xét 46
6.4 Kết luận chung 46

7 Kết luận và định hướng ra quyết định 47
7.1 Hiểu cảm xúc của người dùng trên mạng xã hội 47
7.2 Thấu hiểu khách hàng 48
7.3 Kết luận chung 48

8 Source Code 50

9 Tài liệu tham khảo 51

1 Danh sách thành viên

No.	Fullname	Student ID	Problems	Percentage of work
1	Nguyễn Huy Hoàng	2211091	Tiền xử lý và phân tích dữ liệu	100%
2	Trần Quốc Khánh	2211536	Phương pháp thực hiện với các giải thuật	100%
3	Đinh Nguyễn Việt Khiêm	2211565	Đánh giá dữ liệu	100%

Bảng 1: Bảng phân công công việc nhóm

2 Giới thiệu

Trong thời đại bùng nổ thông tin và mạng xã hội, người dùng Internet không chỉ chia sẻ nội dung mà còn thể hiện cảm xúc, suy nghĩ và quan điểm cá nhân thông qua các bài đăng, bình luận hoặc dòng trạng thái. Lượng dữ liệu văn bản được tạo ra hằng ngày trên các nền tảng như Twitter, Facebook hay Instagram là vô cùng lớn, phản ánh chân thực xu hướng, nhu cầu và tâm lý của người dùng. Việc hiểu được cảm xúc ẩn chứa trong những nội dung này mang ý nghĩa quan trọng đối với nhiều lĩnh vực như marketing, nghiên cứu hành vi khách hàng, phân tích thương hiệu, dự đoán xu hướng xã hội, và hỗ trợ ra quyết định trong kinh doanh.

Tuy nhiên, việc phân tích cảm xúc một cách thủ công từ hàng triệu bình luận hoặc tweet là điều gần như không thể thực hiện được. Các phương pháp truyền thống thường dựa vào đánh giá chủ quan của con người, dẫn đến kết quả thiếu nhất quán, tốn nhiều thời gian và chi phí. Do đó, nhu cầu ứng dụng các phương pháp tự động, đặc biệt là học máy (Machine Learning) và xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP), ngày càng trở nên cấp thiết để trích xuất thông tin và nhận diện cảm xúc trong văn bản một cách hiệu quả.

Đề tài **"Phân tích cảm xúc (Sentiment Analysis) trên dữ liệu Twitter"** được thực hiện với mục tiêu xây dựng một hệ thống có khả năng tự động phân loại cảm xúc của người dùng dựa trên nội dung các tweet. Hệ thống có thể phân biệt được các tweet mang cảm xúc *tích cực* hoặc *tiêu cực*, góp phần hỗ trợ các tổ chức, doanh nghiệp và nhà nghiên cứu trong việc nắm bắt xu hướng tâm lý và dư luận của người dùng trên mạng xã hội.

Trong nghiên cứu này, nhóm sử dụng tập dữ liệu **Sentiment140**, bao gồm 1.600.000 tweet được gán nhãn cảm xúc (0 = tiêu cực, 1 = tích cực). Mỗi bản ghi trong tập dữ liệu chứa các thông tin như nội dung tweet, người đăng, thời gian đăng và nhãn cảm xúc tương ứng. Đề tài tập trung vào các bước chính: *tiền xử lý dữ liệu văn bản*, *xây dựng mô hình học máy* (Machine Learning Models), và *đánh giá hiệu suất mô hình* thông qua các chỉ số như độ chính xác (*Accuracy*), độ bao phủ (*Recall*), và điểm F1 (*F1-Score*).

Mục tiêu chính của đề tài là chứng minh khả năng ứng dụng các kỹ thuật học máy vào việc phân tích cảm xúc trên dữ liệu thực tế, từ đó mở rộng tiềm năng triển khai trong các hệ thống phản hồi khách hàng, đánh giá sản phẩm, hoặc giám sát danh tiếng thương hiệu trên nền tảng trực tuyến.

3 Tiền xử lí dữ liệu

3.1 Tổng quan về dữ liệu

Tập dữ liệu đầu vào mang tên `training.1600000.processed.noemoticon.csv` được trích xuất từ nền tảng **Kaggle** tại đường dẫn `kazanova/sentiment140`. Bộ dữ liệu này được xây dựng nhằm phục vụ các nghiên cứu về *phân tích cảm xúc* trên mạng xã hội Twitter — nơi người dùng thường xuyên bày tỏ cảm xúc, ý kiến và phản hồi của mình về các sự kiện, thương hiệu, sản phẩm hoặc vấn đề xã hội.

Mỗi bản ghi trong tập dữ liệu đại diện cho một dòng *tweet* duy nhất và đã được gán nhãn cảm xúc tương ứng (*tích cực* hoặc *tiêu cực*). Mục tiêu của giai đoạn tiền xử lý là làm sạch, chuẩn hóa và biến đổi dữ liệu văn bản sao cho mô hình học máy có thể hiểu, học và phân loại cảm xúc một cách chính xác và hiệu quả hơn.

Tập dữ liệu gốc bao gồm **1.600.000** mẫu, với **6 cột dữ liệu chính** như sau:

- **target**: Nhãn cảm xúc của tweet (`0 = tiêu cực`, `4 = tích cực`);
- **id**: Mã định danh duy nhất cho từng tweet;
- **date**: Thời điểm đăng tweet;
- **flag**: Thông tin phụ, ví dụ như loại client hoặc từ khóa thu thập;
- **user**: Tên người dùng đăng tweet;
- **text**: Nội dung văn bản của tweet.

	target	id	date	flag	user	text
0	0	1467810369	Mon Apr 06 22:19:45 PDT 2009	NO_QUERY	_TheSpecialOne_	@switchfoot http://twitpic.com/2y1zl - Awww, t...
1	0	1467810672	Mon Apr 06 22:19:49 PDT 2009	NO_QUERY	scotthamilton	is upset that he can't update his Facebook by ...
2	0	1467810917	Mon Apr 06 22:19:53 PDT 2009	NO_QUERY	mattycus	@Kenichan I dived many times for the ball. Man...
3	0	1467811184	Mon Apr 06 22:19:57 PDT 2009	NO_QUERY	ElleCTF	my whole body feels itchy and like its on fire
4	0	1467811193	Mon Apr 06 22:19:57 PDT 2009	NO_QUERY	Karoli	@nationwideclass no, it's not behaving at all....
5	0	1467811372	Mon Apr 06 22:20:00 PDT 2009	NO_QUERY	joy_wolf	@Kwesidei not the whole crew
6	0	1467811592	Mon Apr 06 22:20:03 PDT 2009	NO_QUERY	mybirch	Need a hug
7	0	1467811594	Mon Apr 06 22:20:03 PDT 2009	NO_QUERY	coZZ	@LOLTrish hey long time no see! Yes.. Rains a...
8	0	1467811795	Mon Apr 06 22:20:05 PDT 2009	NO_QUERY	2Hood4Hollywood	@Tatiana_K nope they didn't have it
9	0	1467812025	Mon Apr 06 22:20:09 PDT 2009	NO_QUERY	mimismo	@twittera que me muera ?
1599990	4	2193579249	Tue Jun 16 08:38:59 PDT 2009	NO_QUERY	razzberry5594	WOOOOO! Xbox is back
1599991	4	2193579284	Tue Jun 16 08:38:59 PDT 2009	NO_QUERY	AgustinaP	@rmedina @LaTati Mmmm That sounds absolutely ...
1599992	4	2193579434	Tue Jun 16 08:39:00 PDT 2009	NO_QUERY	sdancingsteph	ReCoVeRiNg FrOm ThE lOnG wEeKeNd
1599993	4	2193579477	Tue Jun 16 08:39:00 PDT 2009	NO_QUERY	ChloeAmisha	@SCOOBY_GRITBOYS
1599994	4	2193579489	Tue Jun 16 08:39:00 PDT 2009	NO_QUERY	EvolveTom	@Cliff_Forster Yeah, that does work better tha...
1599995	4	2193601966	Tue Jun 16 08:40:49 PDT 2009	NO_QUERY	AmandaMarie1028	Just woke up. Having no school is the best fee...
1599996	4	2193601969	Tue Jun 16 08:40:49 PDT 2009	NO_QUERY	TheWDBoards	TheWDB.com - Very cool to hear old Walt interv...
1599997	4	2193601991	Tue Jun 16 08:40:49 PDT 2009	NO_QUERY	bpbabe	Are you ready for your MoJo Makeover? Ask me f...
1599998	4	2193602064	Tue Jun 16 08:40:49 PDT 2009	NO_QUERY	tinydiamondz	Happy 38th Birthday to my boo of alll time!!! ...
1599999	4	2193602129	Tue Jun 16 08:40:50 PDT 2009	NO_QUERY	RyanTrevMorris	happy #charitytuesday @theNSPCC @SparksCharity...

Hình 1: Thông tin cơ bản của tập dữ liệu

Trong phạm vi của đề tài này, chỉ hai cột quan trọng nhất được giữ lại để phục vụ cho quá trình huấn luyện và phân tích cảm xúc:

- **target** – nhãn cảm xúc, được chuyển đổi từ `{0, 4}` sang `{0, 1}` tương ứng với *tiêu cực* và *tích cực*;
- **text** – nội dung gốc của tweet, là nguồn dữ liệu đầu vào cho các mô hình xử lý ngôn ngữ tự nhiên.

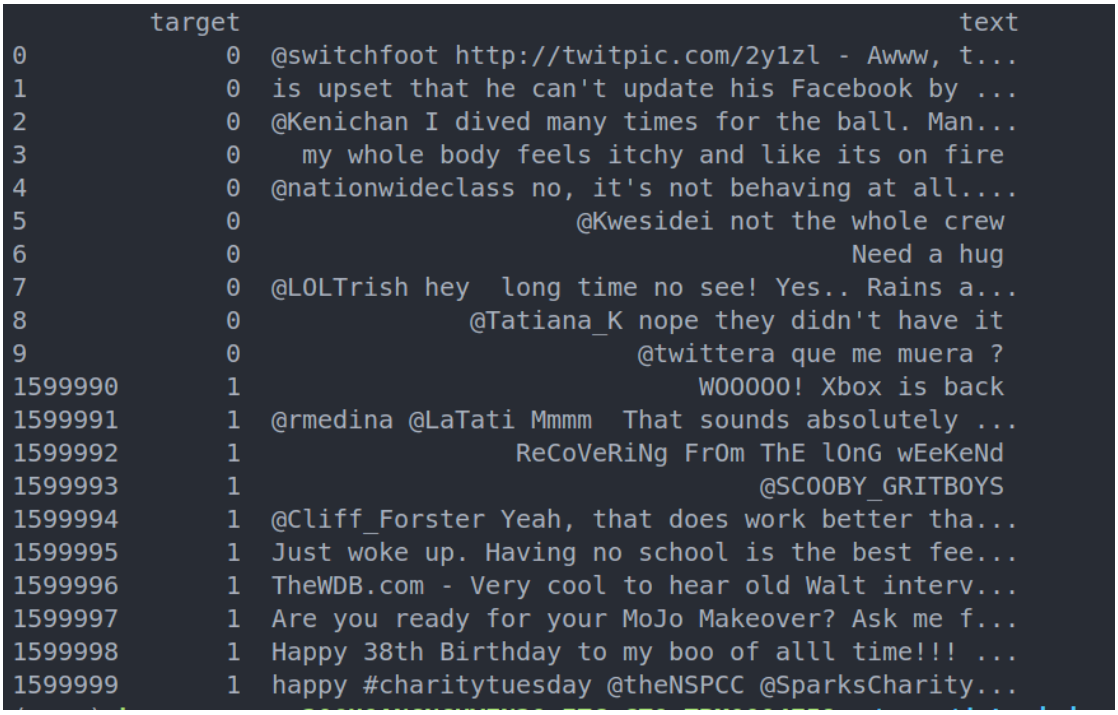

	target	text
0	0	@switchfoot http://twitpic.com/2y1zl - Awww, t...
1	0	is upset that he can't update his Facebook by ...
2	0	@Kenichan I dived many times for the ball. Man...
3	0	my whole body feels itchy and like its on fire
4	0	@nationwideclass no, it's not behaving at all....
5	0	@Kwesidei not the whole crew
6	0	Need a hug
7	0	@LOLTrish hey long time no see! Yes.. Rains a...
8	0	@Tatiana_K nope they didn't have it
9	0	@twittera que me muera ?
1599990	1	WOOOOO! Xbox is back
1599991	1	@rmedina @LaTati Mmmm That sounds absolutely ...
1599992	1	ReCoVeRiNg FrOm ThE lOnG wEeKeNd
1599993	1	@SCOOBY_GRITBOYS
1599994	1	@Cliff_Forster Yeah, that does work better tha...
1599995	1	Just woke up. Having no school is the best fee...
1599996	1	TheWDB.com - Very cool to hear old Walt interv...
1599997	1	Are you ready for your MoJo Makeover? Ask me f...
1599998	1	Happy 38th Birthday to my boo of alll time!!! ...
1599999	1	happy #charitytuesday @theNSPCC @SparksCharity...

Hình 2: Lọc dữ liệu

Các cột còn lại không mang thông tin có giá trị đối với nhiệm vụ nhận diện cảm xúc và do đó đã được loại bỏ nhằm giảm nhiễu dữ liệu, tiết kiệm tài nguyên xử lý và tối ưu hiệu suất của mô hình học máy. Ngoài ra, trong quá trình tiền xử lý, nhóm nghiên cứu cũng xem xét việc loại bỏ các ký tự đặc biệt, liên kết (URL), tên người dùng (`@user`) và biểu tượng cảm xúc (emoji) để chuẩn hóa ngữ liệu đầu vào, giúp mô hình tập trung vào nội dung ngữ nghĩa chính của văn bản.

3.2 Đặc điểm của dữ liệu văn bản Twitter

Dữ liệu thu thập từ nền tảng Twitter có một số đặc điểm riêng biệt so với các loại văn bản truyền thống, như tin tức, bài viết học thuật hoặc tài liệu hành chính. Các đặc trưng này phản ánh tính chất tự nhiên, ngắn gọn và phi cấu trúc của ngôn ngữ người dùng trên mạng xã hội. Cụ thể, dữ liệu Twitter thường có các đặc điểm sau:

- **Biểu tượng cảm xúc (emoji), hashtag (#) và đề cập người dùng (@user):** Đây là các yếu tố phổ biến trong tweet, được sử dụng để thể hiện cảm xúc hoặc gắn thẻ chủ đề và người dùng khác. Tuy nhiên, chúng không phải lúc nào cũng mang giá trị ngữ nghĩa rõ ràng đối với mô hình học máy.
- **Đường dẫn (URL) và liên kết rút gọn:** Nhiều tweet chứa liên kết đến nội dung bên ngoài (ví dụ: `bit.ly`, `t.co`, `goo.gl`). Những đường dẫn này không cung cấp thông tin cảm xúc trực tiếp và thường cần được loại bỏ trong quá trình tiền xử lý.
- **Từ viết tắt, lỗi chính tả và ngôn ngữ phi chính thức:** Người dùng thường viết tắt, sử dụng tiếng lóng, hoặc sai chính tả (ví dụ: *"luv"* thay cho *"love"*, *"omg"*, *"lol"*). Điều này làm tăng độ phức tạp trong việc chuẩn hóa văn bản và trích xuất đặc trưng.
- **Cấu trúc ngữ pháp không chuẩn:** Do giới hạn 280 ký tự, các tweet thường có cấu trúc câu ngắn, rời rạc, thậm chí bỏ qua chủ ngữ hoặc vị ngữ. Điều này khiến các mô hình NLP khó nhận diện đúng ngữ cảnh hoặc mối quan hệ ngữ nghĩa.
- **Tweet rỗng, trùng lặp hoặc chứa ký hiệu đặc biệt:** Một số bản ghi trong tập dữ liệu có thể bị lỗi, chỉ chứa ký tự đặc biệt hoặc lặp lại nội dung. Các trường hợp này cần được phát hiện và loại bỏ để đảm bảo chất lượng dữ liệu đầu vào.

Những đặc điểm trên khiến cho bước **tiền xử lý dữ liệu** trở nên bắt buộc và đóng vai trò then chốt trong toàn bộ quy trình phân tích cảm xúc. Việc xử lý chính xác các yếu tố phi cấu trúc giúp chuyển đổi dữ liệu văn bản tự nhiên thành dạng có thể biểu diễn dưới dạng vector, từ đó hỗ trợ mô hình học máy hiểu và học được ý nghĩa cảm xúc ẩn trong các tweet một cách hiệu quả hơn.

3.3 Các bước tiền xử lý dữ liệu

Để đảm bảo dữ liệu đầu vào có chất lượng cao và phù hợp cho việc huấn luyện mô hình phân tích cảm xúc, nhóm tiến hành một chuỗi các bước **tiền xử lý dữ liệu** (*data preprocessing*). Các thao tác này nhằm loại bỏ nhiễu, chuẩn hóa ngôn ngữ và giảm thiểu sai lệch trong dữ liệu văn bản, qua đó giúp mô hình học máy học được đặc trưng ngữ nghĩa một cách chính xác hơn.

Các bước tiền xử lý này đóng vai trò quyết định đối với chất lượng mô hình phân tích cảm xúc. Việc làm sạch và chuẩn hóa dữ liệu giúp giảm thiểu sai lệch, tăng khả năng khái quát và nâng cao độ chính xác trong quá trình dự đoán cảm xúc của người dùng trên mạng xã hội.

Quy trình tiền xử lý được thực hiện theo các bước sau:

1. **Loại bỏ dữ liệu không cần thiết:** Giữ lại hai cột quan trọng là `target` (nhãn cảm xúc) và `text` (nội dung tweet); các cột như `id`, `date`, `flag`, `user` được loại bỏ để giảm nhiễu và tối ưu kích thước dữ liệu.
2. **Làm sạch văn bản (Text Cleaning):** Loại bỏ URL, tên người dùng (@username), ký hiệu #, số, ký tự đặc biệt và khoảng trắng thừa. Chuẩn hóa toàn bộ văn bản về chữ thường để đảm bảo tính nhất quán.
3. **Loại bỏ từ dừng (Stopwords Removal):** Sử dụng thư viện **NLTK** để loại bỏ các từ dừng tiếng Anh như "the", "is", "and", "at", ... nhằm tập trung vào các từ có giá trị cảm xúc.
4. **Chuẩn hóa từ vựng (Stemming / Lemmatization):** Áp dụng thuật toán **Porter-Stemmer** để đưa các từ về gốc (ví dụ: "running", "runs", "ran" → "run") giúp mô hình nhận diện tốt hơn các biến thể của cùng một từ.
5. **Kết quả sau khi tiền xử lý:** Dữ liệu được chuyển về dạng sạch, thống nhất và chỉ gồm hai cột: `target` – nhãn cảm xúc; `clean_text` – văn bản sau khi xử lý, sẵn sàng cho giai đoạn biểu diễn đặc trưng và huấn luyện mô hình.

3.3.1 Loại bỏ dữ liệu không cần thiết

Trong tập dữ liệu gốc `Sentiment140`, ngoài hai trường quan trọng phục vụ cho bài toán phân tích cảm xúc, còn có nhiều cột thông tin không mang giá trị ngữ nghĩa trực tiếp đối với

mô hình học máy. Cụ thể, các cột như **id**, **date**, **flag** và **user** được loại bỏ trong giai đoạn tiền xử lý, chỉ giữ lại hai trường chính:

- **target** – biểu thị nhãn cảm xúc của tweet, với `0` tương ứng với cảm xúc *tiêu cực* và `1` tương ứng với cảm xúc *tích cực*;
- **text** – nội dung văn bản của tweet, là nguồn dữ liệu đầu vào chính cho các bước xử lý và mô hình học máy.

Việc loại bỏ các trường không cần thiết giúp giảm kích thước tập dữ liệu, tiết kiệm bộ nhớ và thời gian xử lý. Đồng thời, bước này giúp mô hình tập trung hoàn toàn vào các thông tin có ý nghĩa đối với việc học cảm xúc, tránh việc bị nhiễu bởi các đặc trưng không liên quan (như tên người dùng, ngày đăng hoặc mã định danh). Điều này đặc biệt quan trọng trong các hệ thống học máy, nơi mà việc loại bỏ các thuộc tính dư thừa không chỉ giúp tăng tốc độ huấn luyện mà còn cải thiện khả năng khái quát hóa của mô hình trên dữ liệu mới.

3.3.2 Làm sạch văn bản (Text Cleaning)

Dữ liệu văn bản trên mạng xã hội thường chứa nhiều yếu tố gây nhiễu như ký tự đặc biệt, liên kết, hoặc tên người dùng. Do đó, nhóm tiến hành làm sạch dữ liệu bằng cách loại bỏ hoặc chuẩn hóa các thành phần này theo các quy tắc sau:

- **Xóa URL:** Loại bỏ các liên kết bắt đầu bằng `http`, `https` hoặc `www`.
- **Loại bỏ tên người dùng:** Xóa các đề cập (mention) có dạng `@username`.
- **Xóa hashtag:** Loại bỏ ký hiệu `#`, chỉ giữ lại nội dung phía sau để bảo toàn thông tin ngữ nghĩa.
- **Loại bỏ số và ký tự đặc biệt:** Chỉ giữ lại các ký tự chữ cái từ `a-z` nhằm giúp mô hình tập trung vào ngôn ngữ tự nhiên.
- **Chuẩn hóa khoảng trắng:** Loại bỏ khoảng trắng thừa hoặc các ký tự xuống dòng không cần thiết.
- **Chuyển toàn bộ văn bản về chữ thường (lowercasing):** Giúp tránh việc mô hình coi “Happy” và “happy” là hai từ khác nhau.

Sau khi thực hiện các bước trên, văn bản trở nên gọn gàng, đồng nhất và dễ dàng phân tích hơn, tạo nền tảng vững chắc cho các bước xử lý ngôn ngữ tự nhiên tiếp theo.

3.3.3 Loại bỏ từ dừng (Stopwords Removal)

Các từ dừng (stopwords) như "the", "is", "at", "of", "a", "and", ... xuất hiện với tần suất cao trong ngôn ngữ tự nhiên nhưng thường không mang giá trị ngữ nghĩa đáng kể cho việc phân loại cảm xúc. Nhóm sử dụng thư viện **NLTK (Natural Language Toolkit)** để loại bỏ tất cả các từ dừng tiếng Anh khỏi văn bản.

Việc loại bỏ từ dừng giúp:

- Giảm kích thước câu, tiết kiệm tài nguyên tính toán;
- Tăng mức độ tập trung vào các từ khóa thể hiện cảm xúc (ví dụ: "happy", "sad", "angry", ...);
- Cải thiện hiệu quả của bước biểu diễn đặc trưng và huấn luyện mô hình.

3.3.4 Chuẩn hóa từ vựng (Stemming / Lemmatization)

Để giảm độ phức tạp của dữ liệu và gom nhóm các biến thể của cùng một từ về dạng gốc duy nhất, nhóm tiến hành bước **chuẩn hóa từ vựng**. Cụ thể, thuật toán **PorterStemmer** của thư viện **NLTK** được sử dụng để thực hiện *stemming* – cắt bỏ các hậu tố và đưa từ về gốc.

Ví dụ:

- "running", "runs", "ran" → "run"
- "better", "best" → "good"

Bước này giúp mô hình hiểu rằng các từ trên có cùng ý nghĩa hoặc ngữ cảnh tương đồng, từ đó cải thiện khả năng khái quát hóa và hiệu suất học.

3.3.5 Kết quả sau khi tiền xử lý

Sau khi áp dụng đầy đủ các bước tiền xử lý, dữ liệu được chuyển về dạng sạch, thống nhất, chỉ gồm hai cột chính: **target** và **clean_text**.

Ví dụ một số dòng dữ liệu sau khi xử lý:

target	clean_text
0	that bummer shoulda got david carr third day
0	upset cant updat facebook text might cri result school today also blah
0	dive mani time ball manag save rest go bound
0	whole bodi feel itchi like fire
0	behav im mad cant see
1	need hug
1	hey long time see ye rain bit bit lol im fine thank how

Tập dữ liệu sau khi xử lý có tính thống nhất cao, loại bỏ hoàn toàn các yếu tố gây nhiễu và sẵn sàng cho các giai đoạn kế tiếp như *biểu diễn đặc trưng* (feature representation) và *huấn luyện mô hình học máy.*

3.4 Đánh giá chất lượng dữ liệu sau tiền xử lý

Sau khi thực hiện đầy đủ các bước làm sạch và chuẩn hóa văn bản, việc đánh giá chất lượng dữ liệu là cần thiết nhằm đảm bảo tập dữ liệu đạt được độ sạch, tính thống nhất và khả năng phản ánh đúng bản chất cảm xúc của người dùng. Phần này tập trung phân tích ba khía cạnh chính: *(i)* độ sạch dữ liệu, *(ii)* tính cân bằng giữa các nhãn cảm xúc, và *(iii)* phân tích tần suất từ khóa.

3.4.1 Độ sạch và tính thống nhất của dữ liệu

Trước khi tiền xử lý, dữ liệu gốc chứa nhiều yếu tố gây nhiễu như đường dẫn URL, biểu tượng cảm xúc, ký tự đặc biệt, hoặc các từ viết tắt phổ biến trong giao tiếp trực tuyến (ví dụ: `LOL`, `OMG`, `@user`, `http://...`). Những thành phần này không mang giá trị ngữ nghĩa rõ ràng đối với bài toán phân tích cảm xúc và có thể làm sai lệch quá trình học của mô hình.

Sau khi áp dụng quy trình tiền xử lý, các yếu tố không mong muốn này được loại bỏ hoặc chuẩn hóa hoàn toàn. Văn bản trở nên gọn gàng, thống nhất về ngôn ngữ và định dạng, giúp giảm đáng kể số lượng token (từ đơn vị ngữ nghĩa) cần xử lý. Toàn bộ dữ liệu được chuyển về chữ thường (*lowercase*) và chuẩn hóa khoảng trắng, đảm bảo rằng các từ có cùng ý nghĩa nhưng

khác cách viết (chẳng hạn "Happy", "HAPPY", "happy") được nhận diện là một thực thể duy nhất.

Việc chuẩn hóa này không chỉ giúp mô hình giảm độ phức tạp trong quá trình huấn luyện mà còn cải thiện khả năng tổng quát hóa (generalization) trên dữ liệu mới. Kết quả quan sát cho thấy dữ liệu sau xử lý có độ đồng nhất cao, không còn xuất hiện ký tự lạ, emoji hay các chuỗi trống, tạo nền tảng vững chắc cho bước biểu diễn đặc trưng và huấn luyện mô hình học máy ở các phần tiếp theo.

3.4.2 Tính cân bằng giữa các nhãn cảm xúc

Tập dữ liệu `Sentiment140` ban đầu có cấu trúc tương đối cân bằng giữa hai nhãn:

- **0 – Cảm xúc tiêu cực (Negative)**
- **1 – Cảm xúc tích cực (Positive)**

Qua kiểm tra thống kê, tỷ lệ giữa hai nhãn cảm xúc gần như tương đương, mỗi loại chiếm xấp xỉ 50% tổng số mẫu. Sự cân bằng này giúp mô hình học máy tránh được hiện tượng *class imbalance* — khi mô hình có xu hướng dự đoán nhiều hơn cho nhãn có số lượng mẫu lớn hơn. Do đó, tập dữ liệu sau tiền xử lý hoàn toàn đạt tiêu chuẩn về phân phối nhãn cho bài toán phân loại nhị phân.

3.4.3 Phân tích tần suất từ khóa

Phân tích tần suất từ khóa được thực hiện nhằm nhận diện các từ ngữ mang giá trị cảm xúc đặc trưng xuất hiện nhiều trong từng nhóm nhãn.

- **Nhóm cảm xúc tích cực (label = 1):** Các từ xuất hiện nhiều gồm: `love, good, great, happy, fun, thanks, awesome, ...` → Đây là các từ mang sắc thái cảm xúc tích cực rõ rệt, thể hiện niềm vui, sự hài lòng hoặc lòng biết ơn.
- **Nhóm cảm xúc tiêu cực (label = 0):** Các từ phổ biến là: `sad, tired, hate, bad, miss, cry, angry, hurt, ...` → Các từ này thể hiện cảm xúc tiêu cực, buồn bã hoặc thất vọng.

Phân tích này chứng tỏ dữ liệu sau xử lý phản ánh rõ ràng hai xu hướng cảm xúc trái ngược, phù hợp cho việc huấn luyện mô hình phân loại cảm xúc.

3.4.4 Đánh giá tổng thể

Tập dữ liệu sau tiền xử lý đạt được các tiêu chí quan trọng cho một bài toán học máy về xử lý ngôn ngữ tự nhiên. Bảng 2 tóm tắt kết quả đánh giá tổng thể:

Bảng 2: Đánh giá chất lượng dữ liệu sau tiền xử lý

Tiêu chí	**Kết quả đạt được**
Loại bỏ nhiễu và ký tự đặc biệt	Hoàn chỉnh
Chuẩn hóa chữ và khoảng trắng	Đồng nhất
Cân bằng giữa các nhãn cảm xúc	Đạt yêu cầu
Tách rõ sắc thái cảm xúc tích cực / tiêu cực	Rõ ràng
Sẵn sàng cho bước trích xuất đặc trưng và huấn luyện mô hình	Hoàn tất

Như vậy, dữ liệu hiện nay đã đạt chất lượng cao, đảm bảo độ tin cậy và phù hợp để tiến hành các bước tiếp theo trong quy trình phân tích cảm xúc, bao gồm *biểu diễn dữ liệu* (feature extraction) và huấn luyện mô hình học máy (machine learning model training).

4 Phương pháp thực hiện

4.1 K-Nearest Neighbor (KNN)

4.1.1 Cơ sở lý thuyết về K-Nearest Neighbors (KNN)

K-Nearest Neighbors (KNN) là một thuật toán học máy dựa trên phương pháp *instance-based learning*, nghĩa là thuật toán không xây dựng một mô hình tổng quát trong quá trình huấn luyện mà lưu giữ tất cả các điểm dữ liệu trong tập huấn luyện. Khi có một điểm dữ liệu mới cần dự đoán, KNN sẽ dựa vào các điểm gần nhất để đưa ra quyết định phân loại hoặc dự đoán giá trị liên tục (hồi quy).

Ý tưởng chính của KNN như sau: một điểm dữ liệu mới sẽ được gán nhãn dựa trên k hàng xóm gần nhất trong tập huấn luyện, được xác định bằng một tiêu chí đo khoảng cách giữa các điểm. Thuật toán này dựa trên giả định rằng các điểm dữ liệu gần nhau trong không gian đặc trưng sẽ có nhãn giống nhau.

4.1.2 Nguyên lý hoạt động

Để phân loại một điểm dữ liệu mới, KNN thực hiện các bước cơ bản sau:

1. **Tính khoảng cách:** Xác định khoảng cách từ điểm cần phân loại đến tất cả các điểm trong tập huấn luyện.
2. **Chọn k điểm gần nhất:** Lấy k điểm có khoảng cách nhỏ nhất.
3. **Đếm nhãn:** Đếm số lần xuất hiện của từng nhãn trong k điểm.
4. **Gán nhãn:** Gán nhãn phổ biến nhất trong k điểm cho điểm cần phân loại.

4.1.3 Các yếu tố quan trọng

- **Khoảng cách:** Khoảng cách phổ biến nhất là *Euclidean* (khoảng cách Euclide):

$$d(x, y) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}.$$

Ngoài ra, còn có các loại khoảng cách khác:

- **Manhattan distance:** $d(x, y) = \sum_{i=1}^{n} |x_i - y_i|$.
- **Minkowski distance:** $d(x, y) = \left(\sum_{i=1}^{n} |x_i - y_i|^p\right)^{1/p}$, $p \geq 1$.
- **Cosine distance:** $d(x, y) = 1 - \frac{x \cdot y}{\|x\|\|y\|}$, thường dùng trong dữ liệu văn bản.

Lựa chọn khoảng cách phù hợp phụ thuộc vào tính chất dữ liệu và bài toán cụ thể.

- **Giá trị k:** Giá trị k ảnh hưởng trực tiếp đến hiệu quả của KNN:
  - k quá nhỏ: dễ bị nhiễu do các điểm ngoại lai.
  - k quá lớn: làm mất đi đặc điểm cục bộ, giảm độ nhạy.

  Thường chọn k lẻ để tránh tình trạng hòa trong phân loại nhị phân và dùng *cross-validation* để tối ưu k.

- **Trọng số khoảng cách:** Thay vì tính nhãn bằng phiếu bầu bình đẳng, có thể áp dụng *distance weighting*, nghĩa là các điểm gần hơn có ảnh hưởng lớn hơn, ví dụ: trọng số tỉ lệ nghịch với khoảng cách.

- **Chuẩn hóa dữ liệu:** Do KNN dựa trên khoảng cách, các đặc trưng có quy mô khác nhau cần được chuẩn hóa (*scaling*) để tránh đặc trưng lớn chi phối kết quả.

4.1.4 Ưu điểm và nhược điểm

4.1.4.a Ưu điểm

- Dễ hiểu, dễ triển khai và không yêu cầu huấn luyện phức tạp.
- Hiệu quả tốt với dữ liệu có phân bố rõ ràng và ít nhiễu.
- Thích hợp với bài toán multi-class mà không cần thay đổi thuật toán.
- Có thể mở rộng với *distance weighting* để cải thiện hiệu quả phân loại.

4.1.4.b Nhược điểm

- Tốn thời gian và bộ nhớ khi dữ liệu lớn, vì cần tính khoảng cách đến tất cả điểm trong tập huấn luyện.

- Nhạy cảm với nhiễu và đặc trưng không quan trọng.
- Hiệu quả giảm nếu dữ liệu có số chiều cao (*curse of dimensionality*), do khoảng cách giữa các điểm trở nên đồng nhất.
- Cần chuẩn hóa dữ liệu để tránh các đặc trưng có quy mô lớn chi phối.

4.1.5 Ứng dụng

KNN được sử dụng rộng rãi trong nhiều bài toán thực tiễn:

- **Phân loại văn bản:** Nhận dạng chủ đề, phân loại sentiment.
- **Nhận dạng chữ viết tay:** Nhận diện chữ số, chữ cái.
- **Hệ thống gợi ý (*Recommender Systems*):** Dựa trên các user hoặc item gần nhau.
- **Chẩn đoán y khoa:** Dự đoán bệnh lý dựa trên các đặc trưng sinh học.
- **Xử lý hình ảnh:** Nhận dạng đối tượng, phân loại ảnh.

4.1.6 Lưu ý thực tiễn

- KNN thường chạy chậm với tập dữ liệu lớn; có thể sử dụng các cấu trúc như *KD-Tree* hoặc *Ball-Tree* để tăng tốc.
- Việc lựa chọn k, khoảng cách, trọng số và chuẩn hóa dữ liệu là các bước quan trọng để đạt hiệu quả tốt.
- KNN phù hợp với các bài toán có dữ liệu nhỏ đến trung bình và yêu cầu hiểu quả trực quan.

4.1.7 Hiện thực

4.1.7.a Chuẩn bị dữ liệu

```
# ==============================================
# Load dữ liệu
# ==============================================
```

```
file_path = "sentiment140_clean.csv"
data = pd.read_csv(file_path).sample(frac=0.3, random_state=42)
data = data.dropna(subset=['clean_text'])
data['clean_text'] = data['clean_text'].astype(str)

X = data['clean_text']
y = data['target']

# Chia dữ liệu train/test
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)
```

4.1.7.b Hiện thực mô hình

```
# ================================================
# Lấy mẫu để train mô hình
# ================================================
sample_frac = 0.1
X_train_sample = X_train.sample(frac=sample_frac, random_state=42)
y_train_sample = y_train.loc[X_train_sample.index]

# TF-IDF vectorization
vectorizer = TfidfVectorizer(max_features=2000)
X_train_vec = vectorizer.fit_transform(X_train_sample)
X_test_vec = vectorizer.transform(X_test)

# ================================================
# Đánh giá mô hình
# ================================================
def plot_confusion_matrix(y_true, y_pred, model_name):
    cm = confusion_matrix(y_true, y_pred)
```

```
    plt.figure(figsize=(6, 4))
    sns.heatmap(cm, annot=True, fmt='d', cmap='Blues', cbar=False,
                xticklabels=['Negative (0)', 'Positive (1)'],
                yticklabels=['Negative (0)', 'Positive (1)'])
    plt.title(f'Confusion Matrix for {model_name}')
    plt.xlabel('Predicted')
    plt.ylabel('True')
    plt.tight_layout()
    plt.show()
evaluate_model(y_test, y_pred_knn, "K-Nearest Neighbors (TF-IDF)")
```

4.1.7.c Chạy mô hình

```
# ================================================
# Huấn luyện & Dự đoán với KNN
# ================================================
knn_model = KNeighborsClassifier(n_neighbors=5, n_jobs=-1)  # k=5
knn_model.fit(X_train_vec, y_train_sample)

y_pred_knn = knn_model.predict(X_test_vec)
```

4.1.7.d Kết quả thu được

```
============================================================
Đánh giá cho K-Nearest Neighbors (Improved TF-IDF):
============================================================
  Accuracy  : 0.6377
  Precision : 0.6174
  Recall    : 0.7220
  F1 Score  : 0.6656

ROC Curve Analysis:
  AUC Score  : 0.6897
```

Hình 3: Kết quả chạy mô hình K-Nearest Neighbor (KNN)

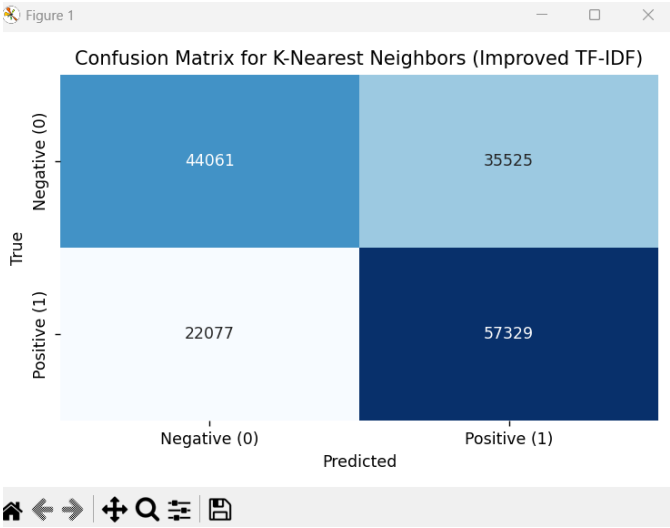

Hình 4: Kết quả chạy mô hình K-Nearest Neighbor (KNN)

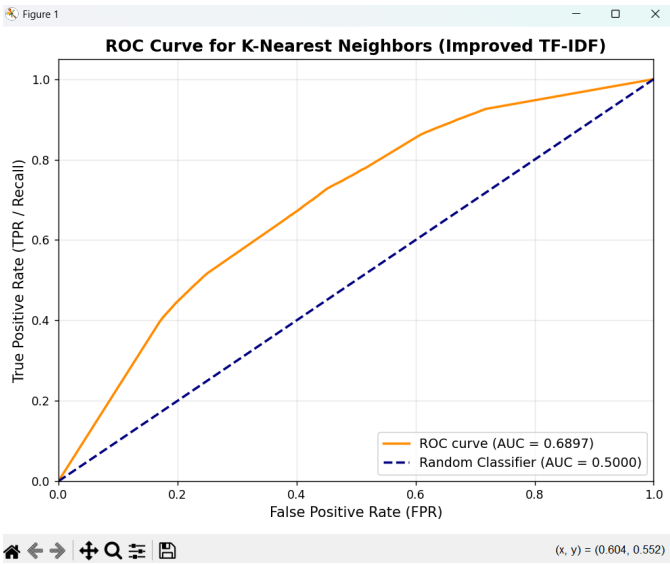

Hình 5: Kết quả chạy mô hình K-Nearest Neighbor (KNN)

4.2 NAIVE BAYES

4.2.1 Cơ sở lý thuyết về Naive Bayes

Naive Bayes là một thuật toán học máy dựa trên *probabilistic learning* và lý thuyết Bayes. Thuật toán này dự đoán nhãn của một điểm dữ liệu mới bằng cách tính xác suất có điều kiện

của các đặc trưng dựa trên nhãn lớp. Mô hình được gọi là *naive* (ngây thơ) vì giả sử rằng các đặc trưng độc lập với nhau, mặc dù trong thực tế chúng có thể có mối quan hệ.

Theo định lý Bayes:

$$P(C|X) = \frac{P(X|C)P(C)}{P(X)}$$

trong đó:

- C là nhãn lớp.
- $X = (x_1, x_2, \ldots, x_n)$ là các đặc trưng.
- $P(C|X)$ là xác suất của lớp C khi biết đặc trưng X.
- $P(X|C)$ là xác suất điều kiện của X khi biết C.
- $P(C)$ là xác suất tiên nghiệm của lớp C.
- $P(X)$ là xác suất của các đặc trưng X.

4.2.2 Cách hoạt động

Để phân loại một điểm dữ liệu mới, Naive Bayes thực hiện các bước:

1. Tính xác suất tiên nghiệm $P(C)$ của từng lớp dựa trên tập huấn luyện.
2. Tính xác suất điều kiện $P(x_i|C)$ cho từng đặc trưng x_i trong điểm dữ liệu.
3. Tính xác suất hậu nghiệm $P(C|X)$ theo định lý Bayes, giả sử các đặc trưng độc lập:

$$P(C|X) \propto P(C) \prod_{i=1}^{n} P(x_i|C)$$

4. Gán nhãn cho lớp có xác suất hậu nghiệm lớn nhất.

4.2.3 Các loại Naive Bayes phổ biến

- **Gaussian Naive Bayes:** Dùng cho dữ liệu liên tục, giả sử các đặc trưng tuân theo phân phối Gaussian.

- **Multinomial Naive Bayes:** Thường dùng cho dữ liệu đếm, ví dụ phân loại văn bản dựa trên số lần xuất hiện từ.
- **Bernoulli Naive Bayes:** Thường dùng cho dữ liệu nhị phân (có/không), ví dụ: từ xuất hiện hay không xuất hiện trong văn bản.

4.2.4 Ưu điểm và nhược điểm

4.2.4.a Ưu điểm

- Dễ hiểu, dễ triển khai và tính toán nhanh.
- Hoạt động tốt với dữ liệu lớn, đặc biệt trong các bài toán phân loại văn bản.
- Hiệu quả tốt ngay cả khi giả định độc lập không hoàn toàn chính xác.
- Yêu cầu ít tài nguyên và dữ liệu huấn luyện.

4.2.4.b Nhược điểm

- Giả định các đặc trưng độc lập có thể không đúng trong thực tế, dẫn đến giảm độ chính xác.
- Không phù hợp với các bài toán mà các đặc trưng có mối quan hệ phức tạp.
- Đối với dữ liệu chưa từng xuất hiện (zero-frequency problem), cần áp dụng *Laplace smoothing* để tránh xác suất bằng 0.

4.2.5 Ứng dụng

Naive Bayes được sử dụng rộng rãi trong nhiều lĩnh vực:

- **Phân loại văn bản:** Spam email, sentiment analysis, phân loại tin tức.
- **Nhận dạng giọng nói và hình ảnh:** Nhận diện mẫu đơn giản.
- **Chẩn đoán y khoa:** Dự đoán bệnh dựa trên các đặc trưng sinh học.
- **Hệ thống gợi ý:** Dựa trên hành vi người dùng và các đặc trưng liên quan.

4.2.6 Lưu ý thực tiễn

- Luôn áp dụng *smoothing* (Laplace) để xử lý các giá trị chưa từng xuất hiện.
- Chuẩn hóa hoặc chuyển đổi dữ liệu phù hợp với loại Naive Bayes đang dùng (Gaussian, Multinomial hoặc Bernoulli).
- Đánh giá hiệu quả bằng *cross-validation* để lựa chọn loại Naive Bayes và các siêu tham số tốt nhất.

4.2.7 Hiện thực

4.2.7.a Chuẩn bị dữ liệu

```
# ================================================
# Chuẩn bị dữ liệu
# ================================================

# Dữ liệu đã được làm sạch
df = pd.read_csv("sentiment140_clean.csv")
df = df.dropna(subset=['clean_text'])
df['clean_text'] = df['clean_text'].astype(str)

# Biến văn bản → TF-IDF (dạng sparse)
vectorizer = TfidfVectorizer(max_features=5000)
X_tfidf = vectorizer.fit_transform(df["clean_text"])
y = df["target"].values

# Chia dữ liệu train / test
X_train, X_test, y_train, y_test = train_test_split(
    X_tfidf, y, test_size=0.3, random_state=42
)
```

4.2.7.b Hiện thực mô hình

```
# ==============================================
# Hàm đánh giá mô hình
# ==============================================

def plot_confusion_matrix(y_true, y_pred, model_name):
    cm = confusion_matrix(y_true, y_pred)
    plt.figure(figsize=(6, 4))
    sns.heatmap(cm, annot=True, fmt='d', cmap='Blues', cbar=False,
                xticklabels=['Negative (0)', 'Positive (1)'],
                yticklabels=['Negative (0)', 'Positive (1)'])
    plt.title(f'Confusion Matrix for {model_name}')
    plt.xlabel('Predicted')
    plt.ylabel('True')
    plt.tight_layout()
    plt.show()


def evaluate_model(y_true, y_pred, model_name):
    print(f"Đánh giá cho {model_name}:")
    print(f"  Accuracy  : {accuracy_score(y_true, y_pred):.4f}")
    print(f"  Precision : {precision_score(y_true, y_pred):.4f}")
    print(f"  Recall    : {recall_score(y_true, y_pred):.4f}")
    print(f"  F1 Score  : {f1_score(y_true, y_pred):.4f}")
    plot_confusion_matrix(y_true, y_pred, model_name)
```

4.2.7.c Chạy mô hình

```
# ==============================================
# Huấn luyện và dự đoán
# ==============================================
```

```
nb_model = MultinomialNB()
nb_model.fit(X_train, y_train)

y_pred_nb = nb_model.predict(X_test)

evaluate_model(y_test, y_pred_nb, "Multinomial Naive Bayes (Sparse TF-IDF)")
```

4.2.7.d Kết quả thu được

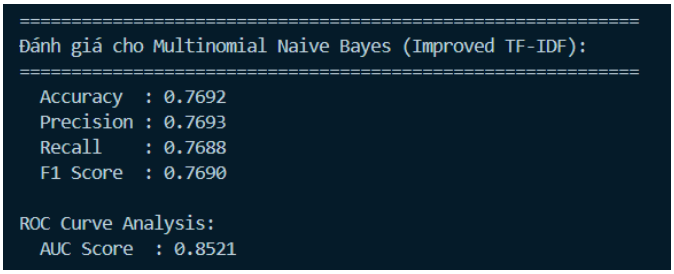

Hình 6: Kết quả chạy mô hình Navie Bayes

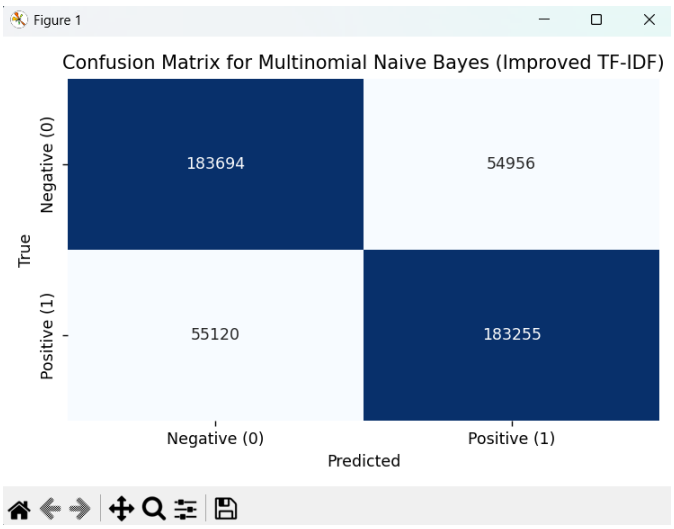

Hình 7: Kết quả chạy mô hình Navie Bayes

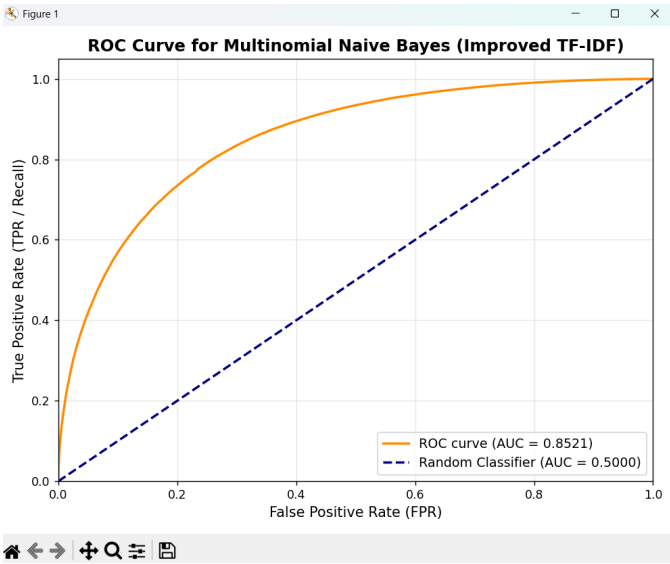

Hình 8: Kết quả chạy mô hình Navie Bayes

4.3 LOGISTIC REGRESSION

4.3.1 Cơ sở lý thuyết về Logistic Regression

Logistic Regression là một thuật toán phân loại nhị phân dựa trên mô hình tuyến tính. Mặc dù có tên "regression", mô hình thực hiện phân loại bằng cách dự đoán xác suất điểm dữ liệu thuộc lớp dương ($y = 1$) thông qua hàm logistic (sigmoid):

$$h_\theta(x) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

Giá trị này nằm trong khoảng $[0, 1]$ và trở thành xác suất để quyết định nhãn phân loại:

$$\hat{y} = \begin{cases} 1 & \text{nếu } h_\theta(x) \geq 0.5 \\ 0 & \text{ngược lại} \end{cases}$$

4.3.2 Hàm mất mát (Binary Cross-Entropy)

Logistic Regression tối ưu tham số θ bằng cách giảm thiểu hàm mất mát:

$$J(\theta) = -\frac{1}{m}\sum_{i=1}^{m}\left[y^{(i)}\log(h_\theta(x^{(i)})) + (1-y^{(i)})\log(1-h_\theta(x^{(i)}))\right]$$

Hàm tối ưu được giải bằng **Gradient Descent** hoặc thuật toán *LBFGS, SAG, SAGA* trong sklearn.

4.3.3 Ưu điểm và Nhược điểm

4.3.3.1 Ưu điểm:

- Mô hình đơn giản, dễ diễn giải.
- Huấn luyện nhanh, phù hợp dữ liệu lớn.
- Hoạt động tốt khi dữ liệu tuyến tính.
- Tránh overfitting tốt với regularization (L1, L2).

4.3.3.2 Nhược điểm:

- Khó mô tả quan hệ phi tuyến nếu không thêm đặc trưng.
- Nhạy cảm với dữ liệu không cân bằng.
- Yêu cầu chuẩn hóa/TF-IDF khi làm NLP để tăng hiệu quả.

4.3.4 Ứng dụng

Logistic Regression được dùng rộng rãi trong:

- Phân loại văn bản: spam detection, sentiment analysis.
- Phân loại rủi ro tài chính.
- Chẩn đoán y khoa.
- Dự đoán hành vi người dùng.

4.3.5 Hiện thực

4.3.5.a Chuẩn bị dữ liệu

```
# ================================================
# Chuẩn bị dữ liệu
# ================================================
df = pd.read_csv("sentiment140_clean.csv")
df = df.dropna(subset=['clean_text'])
df['clean_text'] = df['clean_text'].astype(str)

# TF-IDF (1-2 grams)
vectorizer = TfidfVectorizer(
    max_features=15000,
    ngram_range=(1, 2),
    min_df=2,
    max_df=0.95,
    sublinear_tf=True
)

X_tfidf = vectorizer.fit_transform(df["clean_text"])
y = df["target"]

X_train, X_test, y_train, y_test = train_test_split(
    X_tfidf, y, test_size=0.3, random_state=42, stratify=y
)
```

4.3.5.b Huấn luyện mô hình

```
# ================================================
# Huấn luyện Logistic Regression
# ================================================
log_model = LogisticRegression(
    max_iter=200,
```

```
    C=2.0,
    penalty='l2',
    solver='lbfgs',
    n_jobs=-1
)
log_model.fit(X_train, y_train)

y_pred_log = log_model.predict(X_test)
```

4.3.5.c Đánh giá mô hình

```
# ================================================
# Đánh giá mô hình
# ================================================
evaluate_model(y_test, y_pred_log, "Logistic Regression (TF-IDF)")
```

4.3.5.d Kết quả thu được

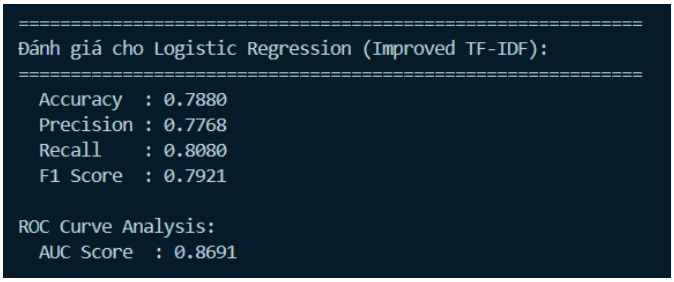

Hình 9: Kết quả chạy mô hình Logistic Regression

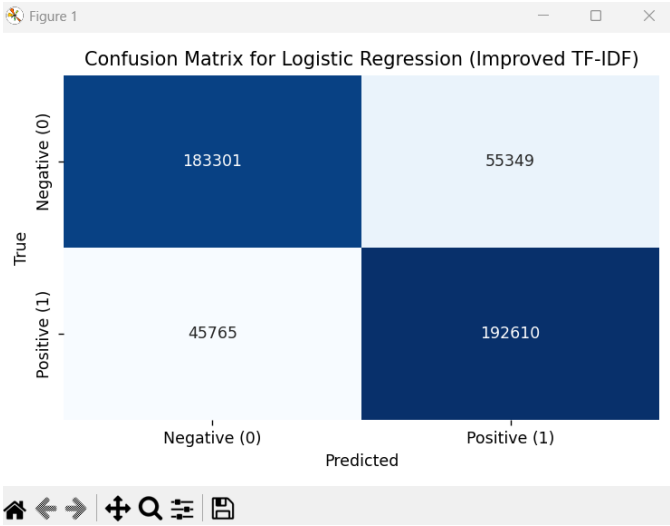

Hình 10: Kết quả chạy mô hình Logistic Regression

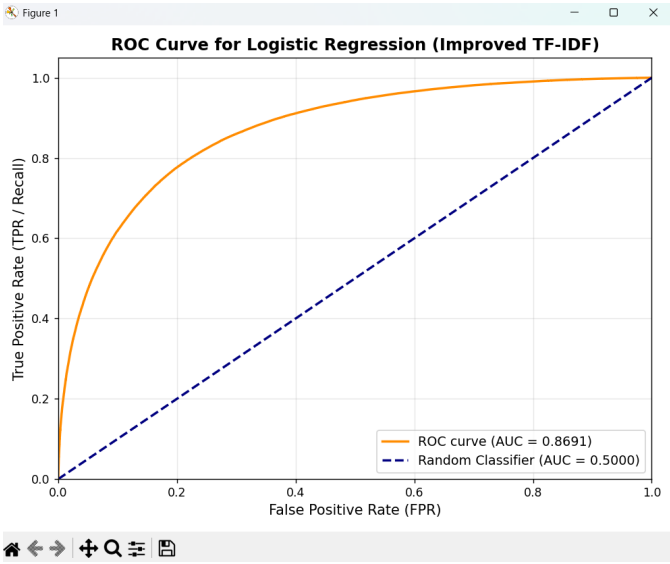

Hình 11: Kết quả chạy mô hình Logistic Regression

5 Đánh giá

5.1 Các chỉ số đánh giá

Để có cái nhìn chính xác và đầy đủ hơn về hiệu quả của mô hình trên tập dữ liệu mất cân bằng, cần sử dụng các chỉ số đánh giá khác tập trung vào hiệu suất phân loại trên từng lớp, đặc biệt là lớp thiểu số. Các chỉ số này bao gồm:

5.1.1 Ma trận Nhầm lẫn (Confusion Matrix)

Đây là công cụ cơ bản và quan trọng nhất, cung cấp cái nhìn chi tiết về kết quả phân loại bằng cách liệt kê số lượng các trường hợp:

- **TP (True Positives):** Mô hình dự đoán là tích cực và mô hình dự đoán đúng
- **TN (True Negatives):** Mô hình dự đoán là tích cực và mô hình dự đoán sai.
- **FP (False Positives):** Mô hình dự đoán là tiêu cực và mô hình dự đoán đúng.
- **FN (False Negatives):** Mô hình dự đoán là tiêu cực và mô hình dự đoán sai.

5.1.2 Accuracy (Độ chính xác tổng thể)

Theo khái niệm học thuật, độ chính xác là tỷ lệ phần trăm tất cả các phân loại chính xác, cho dù là phân loại dương (Positive) hay âm (Negative). Từ đó ta có thể hiểu accuracy là tỷ lệ dự đoán đúng của mô hình trên tổng số dự đoán. Nói cách khác, nó cho biết mô hình đúng được bao nhiêu phần trăm trên toàn bộ dữ liệu kiểm thử. Giá trị này được định nghĩa theo toán học là:

$$\text{Accuracy} = \frac{\text{correct classifications}}{\text{total classifications}} = \frac{TP + TN}{TP + TN + FP + FN}$$

Một mô hình hoàn hảo sẽ không có kết quả dương tính giả (FP) và âm tính giả (FN) nào, do đó, độ chính xác lý tưởng là 1.0 hoặc 100%. Vì chỉ số này kết hợp cả 4 kết quả từ ma trận nhầm lẫn (TP, FP, TN, FN), nên với một tập dữ liệu cân bằng (với số lượng ví dụ tương tự nhau trong cả hai lớp), độ chính xác có thể đóng vai trò là một chỉ số chất lượng mô hình ở mức

độ tổng quát. Đây thường là chỉ số đánh giá mặc định được dùng cho các mô hình chung chung hoặc không xác định thực hiện các tác vụ chung chung hoặc không xác định.

Tuy nhiên, khi tập dữ liệu không cân bằng hoặc khi một loại lỗi (FN hoặc FP) gây tốn kém hơn loại lỗi còn lại (như trong hầu hết các ứng dụng thực tế), thì ta nên tối ưu hoá cho một trong các chỉ số khác (Precision, Recall, F1-Score).

Đối với các tập dữ liệu mất cân bằng nghiêm trọng, trong đó một lớp xuất hiện rất hiếm (ví dụ: 1% thời gian), một mô hình dự đoán âm 100% thời gian sẽ đạt điểm chính xác là 99%, mặc dù mô hình đó hoàn toàn không hữu ích.

5.1.3 Precision (Độ chính xác của dự đoán)

Theo khái niệm học thuật, độ chính xác là tỷ lệ phần trăm tất cả các kết quả phân loại dương tính của mô hình thực sự là dương tính. Đơn giản hơn ta có thể hiểu precision đo lường tỷ lệ các dự đoán tích cực (Positive) là chính xác. Nói cách khác, trong tất cả các mẫu mà mô hình dự đoán là tích cực, có bao nhiêu mẫu thực sự là tích cực. Giá trị này được xác định theo toán học như sau:

$$\text{Precision} = \frac{\text{True Positive (TP)}}{\text{True Positive (TP)} + \text{False Positive (FP)}}$$

Một mô hình hoàn hảo giả định sẽ không có kết quả dương tính giả (False Positive - FP) nào, do đó, độ chính xác (Precision) lý tưởng là 1.0. Trong một tập dữ liệu mất cân bằng, trong đó số lượng ví dụ thực tế là rất thấp (ví dụ: lớp dương tính chỉ chiếm $1 - 2\%$ tổng số mẫu), độ chính xác sẽ ít có ý nghĩa và ít hữu ích hơn dưới dạng một chỉ số đánh giá.

Độ chính xác (Precision) sẽ cải thiện khi số lượng kết quả dương tính giả (FP) giảm (tức là mô hình tự tin hơn khi dự đoán Positive). Ngược lại, độ gợi nhắc (Recall) sẽ cải thiện khi số lượng kết quả âm tính giả (FN) giảm (tức là mô hình tìm được nhiều mẫu Positive thực sự hơn).

Mối quan hệ Nghịch đảo: Việc tăng ngưỡng phân loại có xu hướng làm giảm số lượng kết quả dương tính giả (FP) và tăng số lượng kết quả âm tính giả (FN), trong khi việc giảm ngưỡng sẽ có tác động ngược lại.

Do đó, Precision và Recall thường cho thấy mối quan hệ nghịch đảo, trong đó việc cải thiện

một trong hai chỉ số này sẽ làm giảm chỉ số còn lại. Đây là sự đánh đổi (Trade-off) cơ bản trong các mô hình phân loại.

5.1.4 Recall (Độ bao phủ hay còn là TPR)

Theo khái niệm học thuật, tỷ lệ dương tính thật (recall hoặc TPR), hay tỷ lệ phần trăm tất cả các kết quả dương tính thực tế được phân loại chính xác là dương tính, còn được gọi là tỷ lệ thu hồi. Ta có thể hiểu nó đo lường tỷ lệ các mẫu tích cực (Positive) thực tế được mô hình tìm thấy. Nói cách khác, trong tất cả các mẫu lẽ ra phải được dự đoán là tích cực, có bao nhiêu mẫu đã được mô hình nhận diện đúng. Định nghĩa theo toán học là:

$$\text{Recall} = \frac{\text{True Positive (TP)}}{\text{True Positive (TP)} + \text{False Negative (FN)}}$$

Kết quả âm tính giả (False Negative - FN) là những kết quả dương tính thực tế bị phân loại nhầm là âm tính. Đây chính là lý do chúng xuất hiện trong mẫu số của công thức Recall. Vì vậy nó có tên gọi khác của tỷ lệ thu hồi là xác suất phát hiện (P(Detection)): chỉ số này trả lời câu hỏi: "Trong tất cả các tweet thực sự tích cực, mô hình phát hiện được bao nhiêu phần trăm?"

Một mô hình hoàn hảo giả định sẽ không có kết quả âm tính giả (FN) nào, do đó, tỷ lệ thu hồi (TPR) là 1.0 (tức là tỷ lệ phát hiện là 100%). Trong một tập dữ liệu mất cân bằng, trong đó số lượng thực tế là dương tính rất thấp, tỷ lệ thu hồi là một chỉ số có ý nghĩa hơn so với độ chính xác (Accuracy). Lý do là vì Recall đo lường khả năng của mô hình xác định chính xác tất cả các thực thể dương tính.

Đối với các ứng dụng như dự đoán bệnh tật, việc xác định chính xác các trường hợp dương tính là rất quan trọng. Kết quả âm tính giả (FN) thường có hậu quả nghiêm trọng hơn kết quả dương tính giả (FP), do đó cần ưu tiên tối ưu Recall.

5.1.5 F1-Score (Chỉ số cân bằng Precision và Recall)

F1-Score được định nghĩa là trung bình điều hòa của Precision và Recall, cung cấp một đánh giá cân bằng về khả năng của mô hình. Nó đặc biệt hữu ích khi cần tìm sự cân bằng giữa Precision và Recall, hoặc khi làm việc với các tập dữ liệu mất cân bằng (Imbalanced Datasets),

nơi Accuracy có thể gây hiểu lầm.F1-Score cao cho thấy mô hình đạt được cả Precision cao (ít dương tính giả - FP) và Recall cao (ít âm tính giả - FN).F1-Score đạt giá trị tối đa là 1.0 (hoặc 100%) khi cả Precision và Recall đều đạt 1.0.

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 \times \text{TP}}{2 \times \text{TP} + \text{FP} + \text{FN}}$$

Nói rộng hơn, khi P và R có giá trị gần nhau, F1-Score sẽ gần với giá trị của chúng. Khi P và R khác nhau rất nhiều, F1-Score sẽ tương tự như chỉ số nào kém hơn (có giá trị thấp hơn). F1-Score cung cấp đánh giá cân bằng về khả năng phân loại của mô hình. Nó đặc biệt hữu ích trong các tập dữ liệu mất cân bằng để đảm bảo mô hình không chỉ ưu tiên một chỉ số (Precision hoặc Recall) mà thôi.

5.2 Đánh giá mô hình K-Nearest Neighbors (KNN)

5.2.1 Trực quan hóa kết quả

Để đánh giá trực quan hiệu suất của mô hình KNN thông qua ma trận nhầm lẫn (confusion matrix) - đây là công cụ quan trọng trong phân tích mô hình phân loại, cho phép quan sát trực tiếp số lượng dự đoán đúng và sai theo từng nhãn.

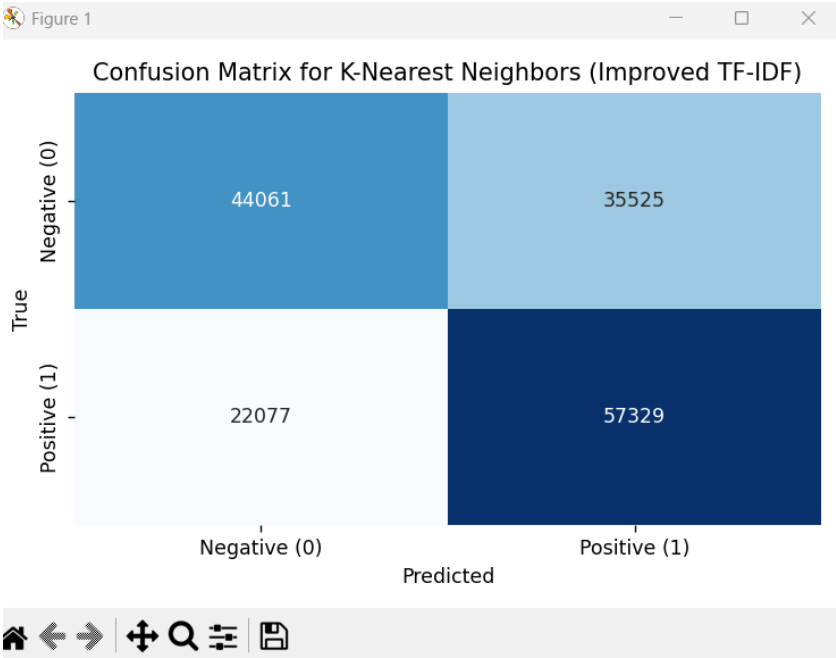

Hình 12: Ma trận nhầm lẫn của mô hình KNN với đặc trưng TF-IDF

Từ ma trận trên, có thể thấy mô hình dự đoán đúng:

- 44,061 tweet tiêu cực (*True Negative*),
- 57,329 tweet tích cực (*True Positive*).

Tuy nhiên, mô hình cũng mắc phải sai lệch đáng kể:

- 35,525 tweet bị dự đoán nhầm sang tích cực (*False Positive*),
- 22,077 tweet tích cực bị bỏ sót và dự đoán thành tiêu cực (*False Negative*).

Các sai lệch này ảnh hưởng trực tiếp đến Precision và F1-score, phản ánh việc mô hình chưa thực sự đáng tin cậy trong việc phân loại tweet tích cực.

5.2.2 Các chỉ số đánh giá tổng hợp

Mô hình KNN đạt được các giá trị:

- **Accuracy**: 0.6377

- **Precision**: 0.6174
- **Recall**: 0.7220
- **F1-score**: 0.6657

Các chỉ số này cho thấy mô hình KNN có khả năng nhận diện tương đối tốt các tweet tích cực (thể hiện qua Recall cao), nhưng độ chính xác trong dự đoán (Precision) lại thấp hơn đáng kể. Điều này dẫn đến F1-score chỉ đạt mức trung bình, phản ánh sự mất cân bằng giữa độ bao phủ và độ tin cậy của mô hình. Hiệu suất chung của KNN bị hạn chế do đặc trưng dữ liệu TF-IDF có số chiều rất lớn, khiến việc đo khoảng cách trong không gian nhiều chiều trở nên kém hiệu quả.

5.2.3 Phân tích đường cong ROC (Receiver Operating Characteristic)

Để đánh giá mô hình một cách toàn diện hơn, sử dụng thêm đường cong ROC, mô tả mối quan hệ giữa:

- **True Positive Rate (TPR / Recall)** – tỷ lệ dự đoán đúng các tweet tích cực,
- **False Positive Rate (FPR)** – tỷ lệ mô hình dự đoán nhầm tweet tiêu cực thành tích cực.

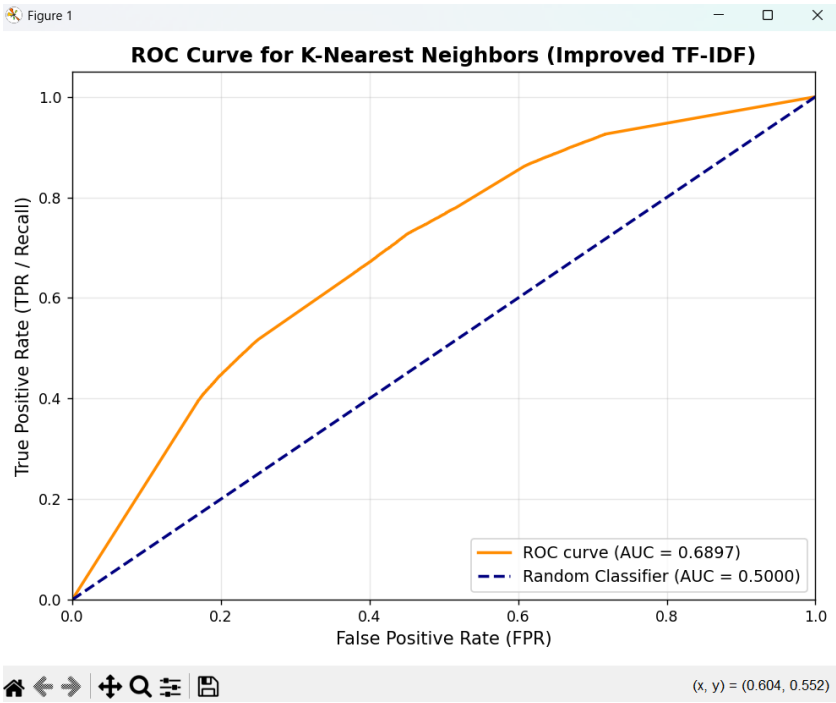

Hình 13: Đường cong ROC của mô hình KNN (Improved TF-IDF)

Quan sát đường cong ROC, có thể nhận thấy:

- Đường ROC luôn nằm phía trên đường chéo của bộ phân loại ngẫu nhiên (AUC = 0.5), cho thấy mô hình có khả năng phân loại tốt hơn mức đoán mò.
- Giá trị AUC = 0.6897 phản ánh khả năng phân tách hai lớp ở mức trung bình, chưa tạo ra ranh giới rõ ràng giữa tích cực và tiêu cực.
- Tại điểm $FPR \approx 0.20$, mô hình đạt TPR khoảng 0.45, nghĩa là khi chỉ cho phép 20% lỗi dự đoán nhầm sang tích cực, mô hình mới nhận diện được gần một nửa số tweet tích cực thật.
- Khi FPR tăng, TPR cũng tăng nhưng không tiến gần đến 1.0 như các mô hình phân loại mạnh hơn.

5.2.4 Kết luận từ ROC Curve

Từ phân tích ROC có thể rút ra:

- Mô hình KNN có hiệu năng ở mức khá nhưng chưa mạnh; AUC < 0.7 cho thấy khả năng phân lớp còn hạn chế.
- Kết hợp với Confusion Matrix (Precision thấp và số lượng False Positive cao), có thể thấy KNN không phù hợp với dữ liệu văn bản lớn.
- Nguyên nhân chủ yếu đến từ việc KNN phải tính khoảng cách trong không gian TF-IDF nhiều chiều, dẫn đến nhiễu và giảm độ phân tách hai lớp.

5.2.5 Nhận xét và kết luận

Tổng hợp các chỉ số đánh giá và biểu đồ trực quan, có thể đưa ra các nhận định chính:

- Mô hình KNN đạt Recall tương đối tốt (0.7250), tức có khả năng nhận diện khá nhiều tweet tích cực thật.
- Tuy nhiên, Precision thấp (0.5949) cho thấy mô hình thường dự đoán nhầm tweet tiêu cực sang tích cực, làm giảm độ tin cậy của mô hình.
- F1-score chỉ đạt 0.6536, cho thấy sự mất cân bằng giữa Recall và Precision.

Bản chất của các vấn đề này bắt nguồn từ đặc thù dữ liệu văn bản:

- Không gian TF-IDF có số chiều rất lớn, khiến việc tính khoảng cách trong KNN trở nên kém hiệu quả.
- Các tweet ngắn, cấu trúc linh hoạt và chứa nhiều từ đa nghĩa gây nhiễu trong việc xác định mức độ tương đồng.

Kết luận: Mô hình KNN không phải lựa chọn tối ưu cho bài toán phân tích cảm xúc dựa trên dữ liệu văn bản lớn. Mặc dù có Recall tương đối tốt, nhưng độ chính xác trong phân loại tích cực thấp và khả năng tổng quát hóa chưa cao.

5.3 Đánh giá mô hình Multinomial Naive Bayes (MNB)

5.3.1 Trực quan hóa kết quả

Tương tự mô hình KNN, sử dụng ma trận nhầm lẫn (Confusion Matrix) để đánh giá trực quan hiệu suất của mô hình Multinomial Naive Bayes khi áp dụng đặc trưng TF-IDF. Đây là

mô hình thường được sử dụng trong phân loại văn bản do giả định độc lập giữa các đặc trưng phù hợp với dữ liệu dạng túi từ (bag-of-words).

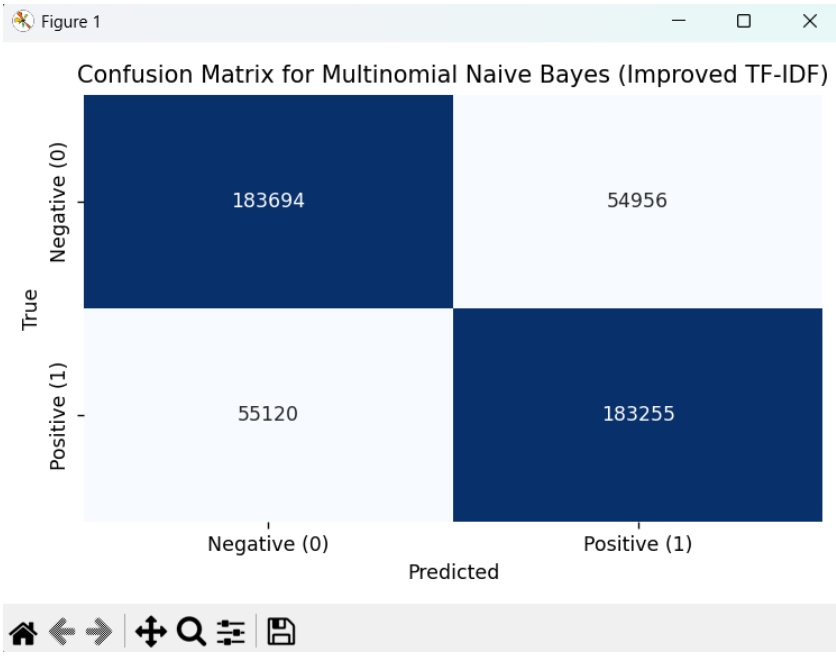

Hình 14: Ma trận nhầm lẫn của mô hình Multinomial Naive Bayes (Improved TF-IDF)

Kết quả từ ma trận nhầm lẫn cho thấy mô hình dự đoán đúng:

- 183,694 tweet tiêu cực (*True Negative*),
- 183,255 tweet tích cực (*True Positive*).

Số lượng sai lệch tương đối thấp:

- 54,956 tweet bị dự đoán nhầm sang tích cực (*False Positive*),
- 55,120 tweet tích cực bị dự đoán sai sang tiêu cực (*False Negative*).

Các giá trị sai lệch nhỏ và cân đối này cho thấy mô hình phân loại tốt cả hai lớp.

5.3.2 Phân tích đường cong ROC (Receiver Operating Characteristic)

Để đánh giá khả năng phân tách hai lớp tích cực/tiêu cực một cách toàn diện, nhóm sử dụng đường cong ROC. Đường cong ROC thể hiện sự thay đổi giữa:

- **True Positive Rate (TPR / Recall)** – khả năng nhận diện đúng các tweet tích cực,
- **False Positive Rate (FPR)** – tỷ lệ mô hình gán nhầm các tweet tiêu cực thành tích cực.

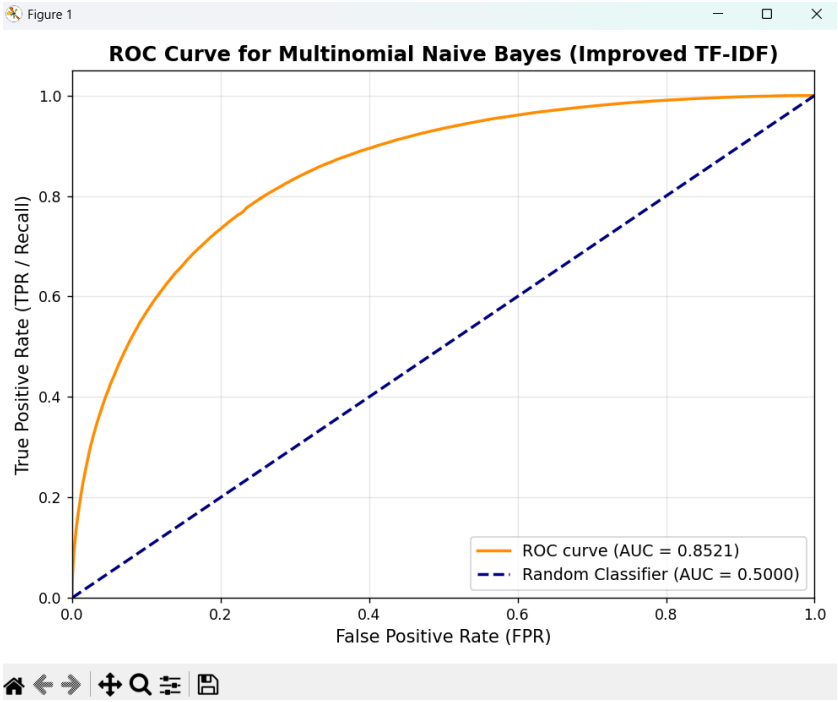

Hình 15: Đường cong ROC của mô hình Multinomial Naive Bayes (Improved TF-IDF)

Quan sát đường cong ROC, có thể rút ra các điểm chính:

- Đường cong nằm khá xa phía trên đường phân loại ngẫu nhiên, chứng tỏ mô hình phân biệt hai lớp rất tốt.
- Giá trị $AUC = 0.8521$ cho thấy hiệu suất phân loại mạnh, vượt xa mô hình KNN trước đó.
- Khi FPR chỉ khoảng 0.10, mô hình đã đạt TPR gần 0.70, nghĩa là với mức lỗi FP rất thấp, mô hình vẫn nhận diện được phần lớn tweet tích cực.
- Khi FPR tăng dần, TPR tiệm cận giá trị 1.0, cho thấy mô hình có khả năng phân tách hai lớp một cách rõ ràng.

5.3.3 Các chỉ số đánh giá tổng hợp

Mô hình Multinomial Naive Bayes đạt được các giá trị:

- **Accuracy**: 0.7692
- **Precision**: 0.7693
- **Recall**: 0.7688
- **F1-score**: 0.7690

Các chỉ số này cao và đồng đều, cho thấy mô hình cân bằng tốt giữa độ bao phủ và độ chính xác trong dự đoán.

5.3.4 Nhận xét và kết luận

Từ các kết quả và biểu đồ trực quan, có thể đưa ra các nhận định sau:

- MNB đạt hiệu năng cao và ổn định, thể hiện qua Precision, Recall và F1-score đều xấp xỉ 0.77.
- AUC = 0.8521 chứng minh mô hình có khả năng phân tách hai lớp rất tốt, vượt trội so với KNN.
- Ma trận nhầm lẫn cho thấy số lượng False Positive và False Negative thấp và cân bằng, giúp mô hình hoạt động tin cậy ở cả hai lớp.

Nguyên nhân khiến mô hình hoạt động hiệu quả là do:

- Kiến trúc Naive Bayes phù hợp với dữ liệu văn bản rời rạc,
- Đặc trưng TF-IDF phản ánh tốt mức độ quan trọng của từ trong câu,
- Giả định độc lập giữa các từ trong văn bản phù hợp với tính chất "bag-of-words".

Kết luận: Multinomial Naive Bayes là mô hình rất phù hợp cho bài toán phân tích cảm xúc trên Twitter. Kết quả ổn định, AUC cao và tỷ lệ lỗi thấp chứng minh khả năng ứng dụng mô hình vào thực tế, đặc biệt là các hệ thống phân tích thương hiệu, đánh giá sản phẩm hoặc giám sát dư luận.

5.4 Đánh giá Mô hình Hồi quy Logistic (Logistic Regression)

5.4.1 Trực quan hóa kết quả

Tương tự các mô hình trước đó, nhóm sử dụng ma trận nhầm lẫn (Confusion Matrix) để đánh giá hiệu suất phân loại của mô hình Hồi quy Logistic khi áp dụng đặc trưng Improved TF-IDF.

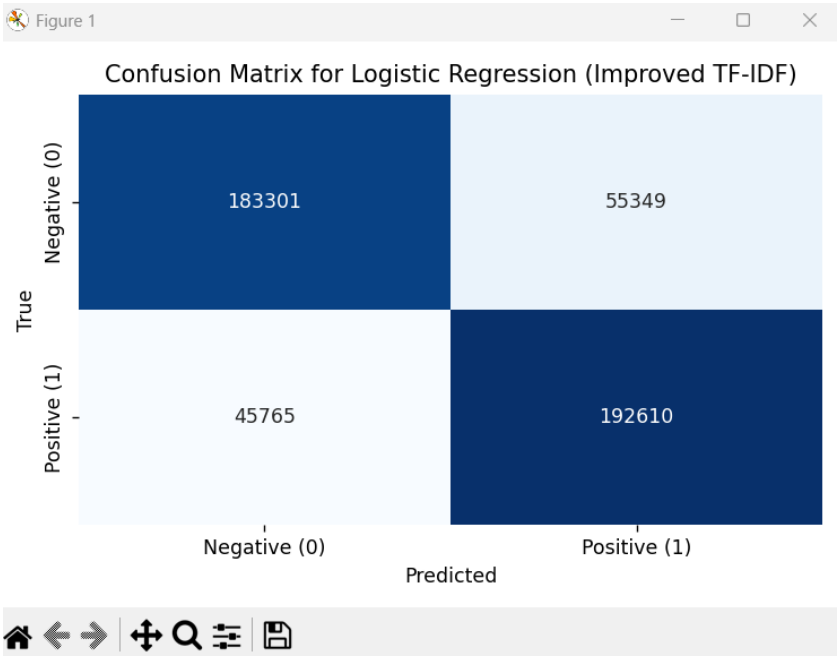

Hình 16: Ma trận nhầm lẫn của mô hình Hồi quy Logistic (Improved TF-IDF)

Từ ma trận nhầm lẫn, mô hình dự đoán đúng:

- 183,301 tweet tiêu cực (*True Negative*, TN),
- 192,610 tweet tích cực (*True Positive*, TP).

Trong khi đó, các sai lệch còn tồn tại gồm:

- 55,349 tweet tiêu cực bị dự đoán nhầm thành tích cực (*False Positive*, FP),
- 45,765 tweet tích cực bị dự đoán nhầm thành tiêu cực (*False Negative*, FN).

Có thể thấy số lượng TN và TP đều cao, trong khi FP và FN tương đối thấp và cân đối. Điều này chứng tỏ mô hình hoạt động hiệu quả và ổn định ở cả hai lớp.

5.4.2 Phân tích Đường cong ROC (Receiver Operating Characteristic)

Để đánh giá khả năng phân tách hai lớp trên mọi ngưỡng cắt, nhóm sử dụng đường cong ROC. Đường cong ROC thể hiện mối quan hệ giữa:

- **True Positive Rate (TPR / Recall)** – khả năng mô hình nhận diện đúng các tweet tích cực,
- **False Positive Rate (FPR)** – tỷ lệ tweet tiêu cực bị phân loại nhầm thành tích cực.

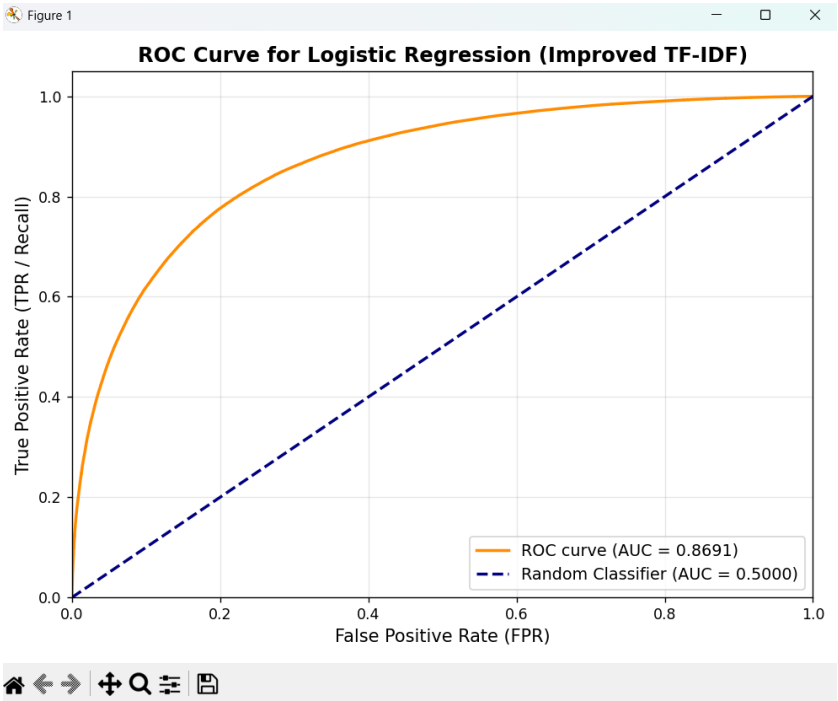

Hình 17: Đường cong ROC của mô hình Hồi quy Logistic (Improved TF-IDF)

Từ đường cong ROC, có thể rút ra các điểm quan trọng:

- Đường cong nằm rất xa phía trên đường phân loại ngẫu nhiên, chứng tỏ khả năng phân biệt hai lớp mạnh mẽ.

- Giá trị AUC = 0.8691 phản ánh hiệu suất phân loại xuất sắc, cao nhất trong ba mô hình được so sánh.
- Khi FPR ≈ 0.20, TPR đạt khoảng 0.80, cho thấy mô hình vẫn nhận diện tốt phần lớn tweet tích cực ngay cả khi chấp nhận một mức lỗi FP tương đối thấp.

5.4.3 Các chỉ số đánh giá tổng hợp

Mô hình Hồi quy Logistic đạt được:

- **Accuracy**: 0.7880
- **Precision**: 0.7768
- **Recall**: 0.8080
- **F1-score**: 0.7921

Các chỉ số đều nằm trong khoảng 0.78 đến 0.81, với Recall cao hơn Precision, cho thấy mô hình có xu hướng ưu tiên nhận diện được nhiều tweet tích cực hơn, kể cả khi phải trả giá bằng một số dự đoán nhầm sang tích cực.

5.4.4 Nhận xét và kết luận

Từ các kết quả thu được, có thể đưa ra một số nhận định:

- Mô hình Hồi quy Logistic đạt hiệu năng cao và ổn định, thể hiện qua $F1_score = 0.7921$ và $Accuracy = 0.7880$.
- Giá trị AUC = 0.8691 vượt trội so với Multinomial Naive Bayes (0.8521) và KNN (0.6897), chứng minh khả năng phân tách hai lớp tốt nhất trong ba mô hình.
- Ma trận nhầm lẫn cho thấy FP và FN đều thấp và tương đối cân bằng, phản ánh độ tin cậy cao trong phân loại hai lớp.

Nguyên nhân giúp mô hình hoạt động hiệu quả:

- Hồi quy Logistic tận dụng tốt đặc trưng Improved TF-IDF, vốn giúp tăng độ phân biệt giữa hai lớp cảm xúc.

- Mô hình tuyến tính phù hợp với không gian TF-IDF chiều cao, nơi ranh giới phân tách có thể được mô hình hóa hiệu quả.

Kết luận: Mô hình Hồi quy Logistic là mô hình mạnh mẽ và phù hợp nhất cho bài toán phân tích cảm xúc trên Twitter trong ba mô hình được so sánh. Với AUC cao nhất và các chỉ số hiệu suất đồng đều, mô hình thể hiện khả năng ứng dụng thực tiễn tốt nhất.

6 So sánh hiệu suất giữa ba mô hình

Để đánh giá toàn diện ba mô hình K-Nearest Neighbors (KNN), Multinomial Naive Bayes (MNB) và Logistic Regression (LR), nhóm tiến hành so sánh thông qua bốn chỉ số quan trọng: Accuracy, Precision, Recall và F1-score. Đây là các thước đo phản ánh mức độ chính xác, khả năng nhận diện và sự cân bằng giữa dự đoán đúng - sai của mỗi mô hình.

6.1 Biểu đồ so sánh hiệu suất

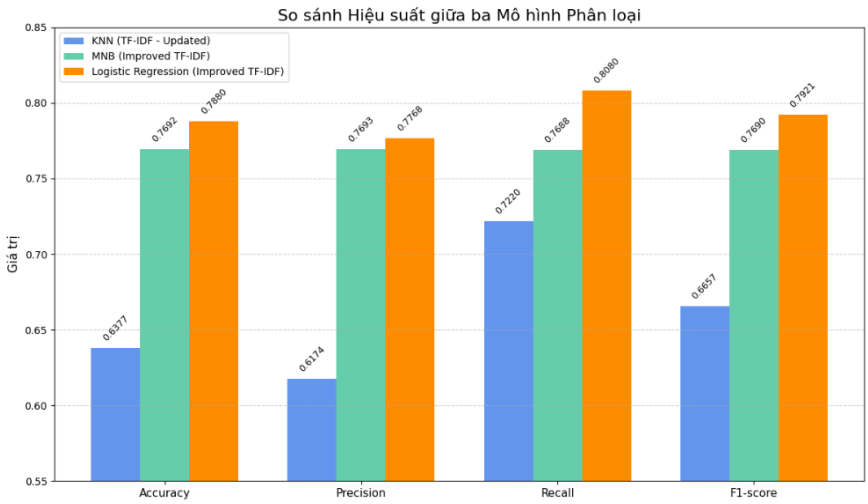

Hình 18: Biểu đồ so sánh Accuracy, Precision, Recall, F1-score giữa ba mô hình

Biểu đồ thanh cho thấy sự khác biệt rõ ràng giữa ba mô hình, trong đó Logistic Regression chiếm ưu thế nổi bật nhất.

6.2 Bảng so sánh chi tiết

Mô hình	Accuracy	Precision	Recall	F1-score
KNN	0.6377	0.6174	0.7220	0.6657
MNB	0.7692	0.7693	0.7688	0.7690
Logistic Regression	0.7880	0.7768	0.8080	0.7921

Bảng 3: So sánh các chỉ số hiệu suất giữa ba mô hình

6.3 Phân tích và nhận xét

Các kết quả thu được cho phép rút ra những điểm quan trọng sau:

- KNN có hiệu suất thấp nhất. Accuracy chỉ đạt 0.6377 và Precision thấp (0.6174) cho thấy mô hình dễ nhầm lẫn giữa hai lớp. Nguyên nhân chính là do không gian TF-IDF có số chiều rất lớn, làm khoảng cách giữa các điểm dữ liệu trở nên kém ý nghĩa, khiến KNN hoạt động không hiệu quả.
- Multinomial Naive Bayes (MNB) hoạt động ổn định và vượt trội hơn KNN. MNB đạt các chỉ số gần như tương đương nhau (≈ 0.769), phản ánh tính ổn định và khả năng xử lý tốt dữ liệu văn bản dạng đếm tần suất. Tuy nhiên, mô hình vẫn hạn chế khi gặp các tweet mơ hồ, đa nghĩa hoặc chứa sarcasm.
- Logistic Regression là mô hình có hiệu suất cao nhất.
  - Accuracy cao nhất: 0.7880
  - F1-score cao nhất: 0.7921
  - Recall vượt trội nhất: 0.8080

  Giá trị AUC cao nhất (0.8691) cho thấy khả năng phân tách hai lớp tốt hơn đáng kể so với MNB và KNN. Điều này chứng minh Logistic Regression phù hợp với không gian vector lớn và đặc trưng tuyến tính của TF-IDF.

6.4 Kết luận chung

Từ các phân tích trên, có thể kết luận:

- KNN không phù hợp cho bài toán phân tích cảm xúc trên dữ liệu văn bản lớn do phụ thuộc mạnh vào khoảng cách trong không gian nhiều chiều.
- Multinomial Naive Bayes là lựa chọn hiệu quả, huấn luyện nhanh, phù hợp khi cần mô hình nhẹ và tốc độ cao.
- Logistic Regression là mô hình tối ưu nhất trong nghiên cứu này, nhờ các chỉ số cao nhất và đường cong ROC vượt trội. Đây là mô hình phù hợp nếu mục tiêu là độ chính xác cao và khả năng vận hành ổn định trên dữ liệu thực tế.

7 Kết luận và định hướng ra quyết định

Dựa trên quá trình đánh giá các mô hình, Logistic Regression được xác định là mô hình tối ưu cho bài toán phân tích cảm xúc trên Twitter, nhờ khả năng phân tách hai lớp tốt (AUC = 0.8691) và các chỉ số hiệu suất đồng đều, cao nhất trong ba mô hình. Điều này cho phép hệ thống phân tích cảm xúc được triển khai một cách ổn định và đáng tin cậy trong thực tế.

Từ mô hình tối ưu này, có thể đưa ra những định hướng quan trọng trong việc hỗ trợ doanh nghiệp thấu hiểu khách hàng và nắm bắt cảm xúc người dùng trên mạng xã hội.

7.1 Hiểu cảm xúc của người dùng trên mạng xã hội

Nhờ khả năng phân loại chính xác các tweet thành tích cực hoặc tiêu cực, hệ thống mang lại cho doanh nghiệp cái nhìn toàn diện về thái độ của người dùng đối với:

- thương hiệu,
- sản phẩm,
- chiến dịch truyền thông.

Hệ thống giúp phát hiện sớm sự thay đổi trong cảm xúc cộng đồng, hỗ trợ doanh nghiệp phản ứng kịp thời trước các vấn đề tiềm ẩn hoặc tình huống khủng hoảng truyền thông.

7.2 Thấu hiểu khách hàng

Từ kết quả phân tích cảm xúc, doanh nghiệp có thể thu thập và khai thác nhiều insight quan trọng:

- Theo dõi phản hồi khách hàng theo thời gian. Mô hình cho phép nhận diện:
  - sự gia tăng bình luận tiêu cực liên quan đến một tính năng hoặc sự cố dịch vụ,
  - các điểm mạnh được người dùng khen ngợi thường xuyên.
- Xác định xu hướng hài lòng hay bất mãn. Hệ thống có thể:
  - phân tích các từ khóa tích cực phổ biến từ các tweet hài lòng,
  - nhận diện các chủ đề gây bất mãn như *"delay", "bad service", "broken"*, ...,
  - theo dõi xu hướng cảm xúc theo từng chiến dịch marketing hoặc mốc thời gian.
- Điều chỉnh chiến dịch marketing hoặc cải tiến sản phẩm. Dựa trên thông tin cảm xúc thu được:
  - doanh nghiệp có thể tăng cường các thông điệp marketing dựa trên điểm mạnh được khen nhiều,
  - điều chỉnh chiến dịch truyền thông khi tỷ lệ cảm xúc tiêu cực tăng,
  - cải thiện sản phẩm hoặc dịch vụ dựa trên phản hồi thực tế của khách hàng.

7.3 Kết luận chung

Kết quả nghiên cứu cho thấy việc lựa chọn Logistic Regression làm mô hình chính cho hệ thống phân tích cảm xúc mang lại nhiều giá trị thiết thực:

- Hiểu cảm xúc của người dùng trên mạng xã hội: xác định mức độ hài lòng hoặc bất mãn đối với thương hiệu, sản phẩm hoặc chiến dịch truyền thông.
- Theo dõi phản hồi khách hàng theo thời gian: phát hiện xu hướng cảm xúc thay đổi để kịp thời ứng phó tình huống truyền thông.
- Xác định Customer Insight: nhận diện chủ đề được khách hàng quan tâm, các yếu tố gây hài lòng hoặc phàn nàn.

- Tối ưu hoá chiến dịch marketing: điều chỉnh thông điệp truyền thông dựa trên cảm xúc và phản hồi thực tế từ người dùng.
- Hỗ trợ cải tiến sản phẩm: tiếp nhận thông tin tiêu cực (ví dụ: "bad service", "delay", "broken") để đưa ra chiến lược cải thiện cụ thể.

Việc tích hợp phân tích cảm xúc vào quy trình kinh doanh mang đến lợi thế cạnh tranh rõ rệt:

- Doanh nghiệp chuyển từ phản ứng bị động sang ra quyết định chủ động dựa trên dữ liệu.
- Cải thiện trải nghiệm khách hàng thông qua việc thấu hiểu nhu cầu và kỳ vọng thực tế.
- Tăng hiệu quả chiến dịch marketing và nâng cao uy tín thương hiệu trên môi trường số.

Hệ thống phân tích cảm xúc không chỉ mang ý nghĩa về mặt kỹ thuật mà còn có tính ứng dụng cao, góp phần hỗ trợ doanh nghiệp đưa ra quyết định chính xác và hiệu quả hơn trong môi trường kinh doanh hiện nay.

8 Source Code

https://github.com/VietKhiem12a5/data_mining_nhom7_HK251

9 Tài liệu tham khảo

References

[1] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. In Proceedings of NAACL, 2019.

[2] J. Edward Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, and Weizhu Chen. *LoRA: Low-Rank Adaptation of Large Language Models*.

[3] Ayoub Kirouane. *Traditional Pruning Methods and Their Impact on Model Size, Accuracy, and Inference Speed*. Retrieved from https://www.linkedin.com/pulse/traditional-pruning-methods-impact-model-size-speed-ayoub-kirouane/

[4] Phan Duy Lưu. *Quantization trong LLM: Tối ưu hóa tốc độ mô hình ngôn ngữ lớn*. Retrieved from https://luu.name.vn/quantization-trong-llm-toi-uu-hoa-toc-do-mo-hinh-ngon-ngu-lon/

[5] Shervin Minaee, Tomá Mikolov, Narjes Nikzad, Meysam Asgari Chenaghlu, Richard Socher, Xavier Amatriain, and Jianfeng Gao. *Large Language Models: A Survey*.

[6] Nebius AI Team. *Inference Optimization Techniques: Solutions*. Retrieved from https://nebius.com/blog/posts/inference-optimization-techniques-solutions

[7] Colin Raffel, Noam M. Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J. Liu. *Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer*. Journal of Machine Learning Research

[8] Ashish Vaswani, Noam M. Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. *Attention is All You Need*. In NeurIPS, 2017.

[9] Cameron R. Wolfe. *Understanding and Using Supervised Learning*. Retrieved from https://cameronrwolfe.substack.com/p/understanding-and-using-supervised

[10] Shengyu Zhang, Linfeng Dong, Xiaoya Li, Sen Zhang, Xiaofei Sun, Shuhe Wang, Jiwei Li, Runyi Hu, Tianwei Zhang, Fei Wu, and Guoyin Wang. *Instruction Tuning for Large Language Models: A Survey*. ArXiv preprint arXiv